PRA-SKRIPSI

KLASIFIKASI KESEGARAN IKAN BANDENG BERDASARKAN CITRA MATA DAN INSANG MENGGUNAKAN *FEATURE-LEVEL FUSION* MOBILENETV3-SMALL DAN SVM

DHIO RIZQI NOVAN SAPUTRA
NPM 23081010277

DOSEN PEMBIMBING
Yisti Vita Via, S.ST., M.Kom.
Ardhon Rakhmadi, S.Tr.T., M.Kom.

KEMENTERIAN PENDIDIKAN, KEBUDAYAAN, RISET, DAN TEKNOLOGI
UNIVERSITAS PEMBANGUNAN NASIONAL VETERAN JAWA TIMUR
FAKULTAS ILMU KOMPUTER
PROGRAM STUDI INFORMATIKA
SURABAYA

2026

DAFTAR ISI

DAFTAR ISI ..... **ii**
DAFTAR GAMBAR ..... **iv**
DAFTAR TABEL ..... **v**
BAB I PENDAHULUAN **1**
1.1. Latar Belakang 1
1.2. Rumusan Masalah 3
1.3. Tujuan Penelitian 4
1.4. Manfaat Penelitian 4
1.5. Batasan Masalah 5
BAB II TINJAUAN PUSTAKA **6**
2.1. Penelitian Terdahulu 6
2.2. Ikan 11
2.3. Ikan Bandeng 12
2.4. Kesegaran Ikan Bandeng Berdasarkan Citra Mata 13
2.5. Kesegaran Ikan Bandeng Berdasarkan Citra Insang 14
2.6. Citra Digital 15
2.7. Pengolahan Citra Digital 17
2.8. *Machine Learning* 18
2.9. *Deep Learning* 20
2.10. Convolutional Neural Network (CNN) 20
2.10.1 *Feature Learning* 21
2.10.2 *Classification* CNN 21
2.11. MobileNetV3-Small 22
2.12. *Feature-Level Fusion* 24
2.13. Arsitektur SVM 25
2.14. *Confusion Matrix* 28
2.15. Metrik Performa 29
2.15.1. Akurasi 29
2.15.2. Presisi 30
2.15.3. *Recall* 30
2.15.4. F1-Score 30

2.16. Flask 31
BAB III METODOLOGI 33
3.1. Metode Penelitian 33
3.2. Studi Literatur 35
3.3. Pengumpulan *Dataset* 35
3.4 *Preprocessing* Data 37
3.5. MobileNetV3-Small dan Support Vector Machine (SVM) 40
3.5.1 Arsitektur MobileNetV3-Small 41
3.5.2 Support Vector Machine (SVM) 44
3.5.3 Simulasi Perhitungan Manual 46
3.6. Skenario Pengujian 49
3.7. Implementasi *Website* 51
DAFTAR PUSTAKA 53

DAFTAR GAMBAR

Gambar 2.1 Mata Ikan Bandeng Segar 13
Gambar 2.2 Mata Ikan Bandeng Tidak Segar 13
Gambar 2.3 Mata Ikan Bandeng Busuk 14
Gambar 2.4 Insang Ikan Bandeng Segar 14
Gambar 2.5 Insang Ikan Bandeng Tidak Segar 15
Gambar 2.6 Insang Ikan Bandeng Busuk 15
Gambar 2.7 Proses Sampling Citra 17
Gambar 2.8 Jenis-jenis *Machine Learning* 18
Gambar 2.9 Arsitektur CNN 21
Gambar 2.10 Arsitektur MobileNetV3-Small 23
Gambar 2.11 Ilustrasi SVM 25
Gambar 2.12 Flask 32
Gambar 3.1 Alur Penelitian 33
Gambar 3.2 Mind Map 34
Gambar 3.3 Sample Data 36
Gambar 3.4 Ilustrasi Persebaran Data 37
Gambar 3.5 Alur *Preprocessing* Data 37
Gambar 3.6 Ilustrasi Resize 38
Gambar 3.7 Ilustrasi Split Data 39
Gambar 3.8 Ilustrasi Augmentasi 40
Gambar 3.9 MobileNetV3-Small dan SVM 40
Gambar 3.10 Alur MobileNetV3-Small 41
Gambar 3.11 Alur SVM 45
Gambar 3.12 *Wireframe Website* 51

DAFTAR TABEL

Tabel 2.1 Penelitian Terdahulu 8
Tabel 2.2 Confusion Matrix 28
Table 3.1 Jumlah Data per Kelas 36
Table 3.2 Arsitektur MobileNetV3-Small..... 42
Table 3.3 Vektor Fitur Ilustratif Citra Mata dan Insang 46
Table 3.4 Vektor Fitur Gabungan (F), Vektor Fitur Pendukung (Fsv) dan Vektor Bobot (w)..... 47
Table 3.5 Skenario Pengujian..... 50

BAB I
PENDAHULUAN

1.1.Latar Belakang

Ikan merupakan salah satu sumber protein hewani yang banyak dikonsumsi oleh masyarakat, termasuk di Indonesia [1]. Ikan bandeng (*Chanos chanos*) merupakan salah satu komoditas perikanan air payau yang banyak diminati dan dibudidayakan [2]. Kabupaten Sidoarjo merupakan salah satu wilayah yang dikenal sebagai sentra budidaya dan pengolahan ikan bandeng, salah satunya Desa Kalanganyar, Kecamatan Sedati [3]. Kondisi tersebut menjadikan ikan bandeng sebagai salah satu komoditas yang relevan untuk dikembangkan, termasuk dalam penerapan teknologi untuk membantu penilaian kualitas dan kesegarannya.

Kesegaran ikan merupakan salah satu faktor penting yang menentukan mutu, cita rasa, tekstur, dan kelayakan ikan untuk dikonsumsi. Setelah ikan mengalami kematian, kualitasnya akan mengalami perubahan yang dapat diamati melalui karakteristik fisik dan sensorik, seperti kondisi mata, warna insang, tekstur, dan aroma [4]. Penilaian kesegaran secara manual masih bergantung pada pengamatan dan pengalaman individu sehingga dapat menimbulkan perbedaan dalam menentukan tingkat kesegaran. Oleh karena itu, diperlukan pendekatan berbasis citra yang dapat membantu proses klasifikasi secara lebih objektif dan terukur.

Mata dan insang merupakan bagian tubuh ikan yang memiliki karakteristik visual yang dapat berubah selama proses penurunan kesegaran. Penelitian yang memanfaatkan karakteristik warna mata dan insang mendapati bahwa kedua bagian tersebut dapat digunakan sebagai sumber informasi dalam sistem otomatis untuk mendeteksi kualitas ikan [5]. Penelitian lain juga memanfaatkan citra mata untuk mendeteksi tingkat kesegaran ikan menggunakan *deep learning* dan *machine learning,* dan mendapati bahwa karakteristik visual mata dapat digunakan sebagai informasi klasifikasi kesegaran [6]. Berdasarkan penelitian tersebut, mata dan insang dipilih sebagai sumber informasi visual dalam penelitian ini.

Pada ikan bandeng, penelitian terdahulu telah menerapkan metode berbasis *deep learning* untuk klasifikasi kesegaran. [7] membandingkan beberapa arsitektur Convolutional Neural Network (CNN), yaitu VGG16, ResNet50, MobileNetV1, dan Xception, berdasarkan citra mata ikan bandeng dengan dua kategori kesegaran, yaitu segar dan tidak segar. Penelitian lain mengembangkan sistem identifikasi kesegaran

ikan bandeng secara non-kontak menggunakan SSD untuk deteksi objek dan MobileNetV2 untuk klasifikasi dengan tiga kategori, yaitu sangat segar, segar, dan tidak segar, serta memperoleh akurasi sebesar 81,6% [8]. Studi lainnya mengklasifikasikan kesegaran ikan bandeng berdasarkan citra mata menggunakan algoritma Support Vector Machine (SVM) dengan dua kategori kesegaran, yaitu segar dan tidak segar [9]. Citra diubah menjadi 64x64 piksel, dinormalisasikan, dan diratakan (*flatten)* menjadi vektor fitur sebelum diklasifikasikan, dengan akurasi tertinggi sebesar 94,17% pada kernel Polynomial [9]. Ketiga penelitian ini menunjukkan bahwa citra ikan bandeng dapat dimanfaatkan untuk klasifikasi kesegaran, baik dengan pendekatan deep learning maupun machine learning, tetapi sumber informasi citra yang digunakan belum menggabungkan karakteristik mata dan insang dalam satu representasi fitur.

Pemanfaatan citra mata dan insang secara bersamaan telah diterapkan pada objek ikan lain. [10] menggunakan citra mata dan insang ikan Mungkus untuk klasifikasi kesegaran menggunakan algoritma Naïve Bayes dan melaporkan akurasi 66%. Penelitian lanjutan menggunakan CNN pada objek yang sama dengan memanfaatkan citra mata dan insang, tetapi kedua sumber citra masih diproses secara terpisah sehingga belum membentuk satu representasi fitur gabungan untuk menghasilkan satu keputusan klasifikasi [11]. Kondisi tersebut membuka peluang untuk mengembangkan metode yang memanfaatkan informasi dari mata dan insang secara bersama dalam satu proses klasifikasi.

Penggunaan CNN juga memberikan keuntungan dalam mempelajari fitur visual secara otomatis dari citra tanpa harus menentukan fitur secara manual. Penelitian [12] membandingkan CNN dengan pendekatan ekstraksi fitur Gray Level Co-occurrence Matrix (GLCM) pada klasifikasi daun herbal. CNN tanpa ekstraksi manual memberikan hasil klasifikasi yang lebih baik pada kondisi pencahayaan tertentu, dengan nilai akurasi, *precision*, *recall*, dan F1-score yang dapat mencapai 98%. Hasil ini mengindikasikan potensi ekstraksi fitur otomatis dalam memperoleh representasi visual untuk proses klasifikasi citra.

Selain kemampuan ekstraksi fitur secara otomatis, pemilihan arsitektur yang efisien diperlukan untuk memperoleh representasi fitur dengan beban komputasi yang lebih ringan. Penelitian [13] membandingkan beberapa varian MobileNet yang dipadukan dengan beberapa algoritma *machine learning*, termasuk Support Vector

Machine (SVM), pada klasifikasi citra biologis. Kombinasi MobileNetV3-Small dan SVM memperoleh akurasi sebesar 0,955 dan F1-score sebesar 0,948. Hasil tersebut menjadi dasar penelitian pemilihan MobileNetV3-Small sebagai ekstraktor fitur dan SVM sebagai *classifier* dalam penelitian ini.

Berdasarkan penelitian terdahulu yang telah ditinjau, penelitian pada ikan bandeng masih banyak memanfaatkan satu sumber citra, seperti citra mata atau citra bagian tubuh ikan secara umum [8]. Sementara itu, penelitian yang menggunakan citra mata dan insang pada objek ikan lain masih melakukan pemrosesan kedua sumber citra secara terpisah [10]. Berdasarkan penelitian yang ditinjau dalam penelitian ini, terdapat peluang untuk menggabungkan fitur yang diperoleh dari citra mata dan citra insang menjadi satu representasi sebelum proses klasifikasi. Oleh karena itu, penelitian ini mengusulkan penggunaan *feature-level fusion* untuk menggabungkan fitur citra mata dan citra insang dalam satu representasi fitur sebelum dilakukan klasifikasi menggunakan SVM. MobileNetV3-Small digunakan sebagai ekstraktor fitur untuk memperoleh representasi visual dari masing-masing citra, kemudian fitur dari kedua sumber digabungkan melalui operasi *concatenation* sebelum diklasifikasikan menggunakan SVM.

Penelitian ini menggunakan tiga kategori kesegaran, yaitu Segar, Tidak Segar, dan Busuk. Penggunaan tiga kategori ini memungkinkan proses klasifikasi membedakan tingkat kesegaran ikan secara lebih terperinci. Penerapan tiga kondisi kesegaran dalam sistem berbasis citra dengan menggunakan SVM juga telah dilakukan pada penelitian sebelumnya [14]. Untuk mendukung proses *feature-level fusion*, citra mata dan citra insang diperoleh dari individu ikan bandeng yang sama pada kondisi kesegaran yang sama. Dengan demikian, setiap sampel terdiri atas pasangan citra mata dan citra insang yang memiliki identitas ikan serta kelas kesegaran ikan yang sama. Berdasarkan permasalahan dan peluang penelitian tersebut, penelitian ini mengembangkan klasifikasi kesegaran ikan bandeng menggunakan MobileNetV3-Small sebagai ekstraktor fitur, *feature-level fusion* melalui *concatenation* untuk menggabungkan fitur citra mata dan insang, serta SVM sebagai *classifier* untuk menghasilkan satu keputusan klasifikasi.

1.2. Rumusan Masalah

Mengacu pada latar belakang yang telah dijabarkan, rumusan masalah dalam penelitian ini adalah sebagai berikut:

1. Bagaimana implementasi MobileNetV3-Small sebagai ekstraktor fitur dan Support Vector Machine (SVM) sebagai algoritma klasifikasi dengan skema *feature-level fusion* untuk mengklasifikasikan kesegaran ikan bandeng berdasarkan citra mata dan insang?
2. Bagaimana hasil performa model MobileNetV3-Small dan SVM dalam mengklasifikasikan kesegaran ikan bandeng ke dalam tiga kategori, yaitu Segar, Tidak Segar, dan Busuk, berdasarkan metrik evaluasi yang digunakan?
3. Bagaimana pengaruh penggabungan fitur dari citra mata dan citra insang terhadap performa klasifikasi ikan bandeng dibandingkan dengan penggunaan citra mata atau citra insang secara individual?
4. Bagaimana implementasi model klasifikasi kesegaran ikan bandeng yang telah dilatih ke dalam aplikasi berbasis berbasis website menggunakan *framework* Flask sehingga pengguna dapat mengunggah pasangan citra mata dan insang serta memperoleh hasil klasifikasinya?

1.3. Tujuan Penelitian

Berdasarkan rumusan masalah yang telah ditetapkan, tujuan penelitian ini adalah sebagai berikut:

1. Mengimplementasikan MobileNetV3-Small sebagai ekstraktor fitur dan SVM sebagai algoritma klasifikasi dengan skema *feature-level fusion* untuk mengklasifikasikan kesegaran ikan bandeng berdasarkan citra mata dan insang.
2. Mengevaluasi performa model dalam mengklasifikasikan kesegaran ikan bandeng ke dalam tiga kategori, yaitu Segar, Tidak Segar, dan Busuk, menggunakan metrik evaluasi seperti akurasi, presisi, recall, dan F1-score.
3. Menganalisis pengaruh penggabungan fitur dari citra mata dan citra insang terhadap performa klasifikasi dibandingkan dengan penggunaan citra mata atau citra insang secara individual.
4. Mengimplementasikan model klasifikasi kesegaran ikan bandeng yang telah dilatih ke dalam aplikasi berbasis website menggunakan *framework* Flask.

1.4. Manfaat Penelitian

Dengan dilaksanakannya penelitian ini, diharapkan dapat memberikan manfaat sebagai berikut:

1. Memberikan penerapan pendekatan *computer vision* dan *machine learning* dalam klasifikasi kesegaran ikan bandeng menggunakan MobileNetV3-Small, *feature-level fusion*, dan SVM.
2. Memberikan informasi mengenai pemanfaatan citra mata dan citra insang sebagai sumber informasi visual yang dapat digunakan secara bersama dalam klasifikasi kesegaran ikan bandeng.
3. Menjadi referensi bagi peneliti selanjutnya dalam pengembangan metode penggabungan informasi dari beberapa citra atau bagian objek pada permasalahan klasifikasi kesegaran hasil perikanan.
4. Menyediakan aplikasi berbasis website yang memudahkan pengguna mengetahui tingkat kesegaran ikan bandeng dengan mengunggah pasangan citra mata dan insang.

1.5. Batasan Masalah

Adapun batasan-batasan masalah yang menjadi fokus dalam penelitian ini adalah sebagai berikut:

1. Objek penelitian terbatas pada ikan bandeng (*Chanos chanos*).
2. Data masukan berupa satu citra mata dan satu citra insang yang berasal dari individu ikan bandeng yang sama, diambil pada kondisi kesegaran yang sama dalam setiap sampel multimodal.
3. Ekstraksi fitur visual dilakukan menggunakan arsitektur CNN MobileNetV3-Small.
4. Fitur yang diperoleh dari citra mata dan citra insang digabungkan menggunakan skema *feature-level fusion* melalui proses *concatenation.*
5. Klasifikasi fitur gabungan dilakukan menggunakan algoritma Support Vector Machine (SVM)
6. Kategori kesegaran yang digunakan terdiri atas tiga kelas, yaitu Segar, Tidak Segar, dan Busuk.
7. Data citra diperoleh melalui pengambilan data secara langsung dan digunakan sebagai *dataset* penelitian.

BAB II
TINJAUAN PUSTAKA

2.1. Penelitian Terdahulu

Penelitian yang berkaitan dengan klasifikasi kesegaran ikan telah banyak dilakukan dengan berbagai metode berbasis pengolahan citra dan kecerdasan buatan. Beberapa penelitian juga telah memanfaatkan kombinasi ekstraktor fitur berbasis *deep learning* dengan algoritma *machine learning* konvensional untuk meningkatkan performa klasifikasi, serta memanfaatkan lebih dari satu bagian tubuh ikan sebagai sumber informasi visual. Berikut beberapa penelitian terdahulu yang relevan dengan penelitian ini.

Peneliti [7] pada tahun 2021 melakukan penelitian berjudul "Perbandingan Convolutional Network untuk Klasifikasi kesegaran Ikan Bandeng pada Citra Mata". Penelitian ini membandingkan performa beberapa arsitektur CNN, yaitu VGG16, ResNet50, MobileNetV1, dan Xception, dalam mengklasifikasikan tingkat kesegaran ikan bandeng ke dalam dua kategori (segar dan tidak segar) berdasarkan citra mata sebanyak 154 citra. VGG16 menghasilkan akurasi tertinggi, yaitu 97%. Penelitian ini relevan karena objek penelitian sama, yaitu ikan bandeng, meski hanya memanfaatkan satu sumber citra (mata) dan klasifikasi dua kelas.

Peneliti [8] mengembangkan aplikasi identifikasi kesegaran ikan bandeng non-kontak dengan mengombinasikan *Single ShotMultibox Detector* (SSD) untuk deteksi objek kepala dan ekor ikan, serta MobileNetV2 untuk mengklasifikasikan kesegaran ke dalam tiga kelas, yaitu sangat segar, segar, dan tidak segar. Model diuji pada 312 citra ikan bandeng dan mencapai akurasi global sebesar 81,6%, dengan kinerja klasifikasi masing-masing kelas sebesar 97%, 70%, dan 80%. Penelitian ini menunjukkan bahwa skema klasifikasi tiga kelas kesegaran dapat diterapkan pada ikan bandeng menggunakan arsitektur MobileNet, meskipun citra yang digunakan adalah citra kepala dan ekor ikan secara utuh, bukan citra mata maupun insang secara spesifik.

Peneliti [9] berjudul "Identifikasi Kualitas Ikan Bandeng Melalui Citra Mata Menggunakan SVM" mengembangkan sistem identifikasi kesegaran ikan bandeng berdasarkan citra mata ke dalam dua kategori, yaitu segar dan tidak segar. Data terdiri atas 100 citra mata ikan segar dan 100 citra mata ikan tidak segar yang diperoleh melalui pemotretan langsung dan sumber daring, kemudian diperbanyak menjai 800 citra melalui augmentasi berupa rotasi 90 derajat, flip horizontal, dan flip vertikal.

Setiap citra diubah ukurannya menjadi 64x64 piksel, dinormalisasikan ke rentang [0,1], dan diratakan menjadi vektor fitur berdimensi 12.288 sebagai masukan SVM. Pengujian dilakukan dengan membandingkan kernel Linear dan Polynomial serta nilai C sebesar 1 dan 0,1. Kernel Polynomial dengan C = 0,1 menghasilkan akurasi tertinggi, yaitu 94,17%, sedangkan kernel Linear menghasilkan akurasi 93,33%. Penelitian ini relevan karena objeknya sama, yaitu ikan bandeng, dan menggunakan SVM sebagai algoritma klasifikasi.

Peneliti [15] melakukan penelitian berjudul "Identifikasi Kesegaran Ikan Menggunakan Algoritma KNN Berbasis Citra Digital". Penelitian tersebut menggunakan citra mata ikan dan fitur warna RGB untuk mengidentifikasi tingkat kesegaran ikan menggunakan algoritma K-Nearest Neighbor (KNN). Data yang digunakan terdiri dari 150 citra mata ikan yang diambil pada beberapa interval waktu penyimpanan. Citra mata terlebih dahulu melalui proses cropping, segmentasi, dan ekstraksi nilai RGB sebelum dilakukan klasifikasi. Hasil pengujian menunjukkan bahwa nilai akurasi tertinggi diperoleh pada nilai K=1, yaitu sebesar 93,33%. Penelitian ini relevan dengan penelitian yang dilakukan karena sama-sama memanfaatkan citra mata sebagai sumber informasi visual dalam identifikasi kesegaran ikan.

Peneliti [16] melakukan identifikasi kesegaran ikan laut berdasarkan citra Hue Saturation Value (HSV) pada insang dan Local Binary Pattern (LBP) pada mata, yang kemudian diklasifikasikan menggunakan K-Nearest Neighbor (KNN). Setelah 45 kali pengujian pada setiap metode, fitur HSV pada insang menghasilkan tingkat keberhasilan tertinggi 90%, sedangkan fitur tekstur pada mata menghasilkan 85%. Penelitian ini relevan karena turut memanfaatkan informasi mata dan insang secara kebersamaan, meskipun kedua citra tersebut masih diproses dan dievaluasi menggunakan fitur serta *classifier* yang berbeda untuk masing-masing bagian tubuh ikan, bukan melalui satu skema penggabungan fitur.

Peneliti [10] melalui penelitian berjudul "Automated Classification of Mungkus Fish Freshnes Based on Eye and Gill Images Using the Naïve Bayes Algorithm" memanfaatkan citra mata dan insang ikan mungkus untuk mengklasifikasikan tingkat kesegaran menggunakan algoritma Naïve Bayes, dengan akurasi yang dilaporkan sekitar 66%. Kedua citra tersebut diproses secara terpisah sehingga informasi dari mata dan insang menghasilkan keputusan klasifikasi masing-masing, bukan sebagai satu

representasi gabungan untuk satu ekor ikan yang sama. Penelitian lanjutan dari tim yang sama beralih menggunakan pendekatan Convolutional Neural Network (CNN), namun citra mata dan insang tetap dievaluasi secara terpisah tanpa skema penggabungan fitur [11]. Penelitian inilah yang menjadi salah satu motivasi utama dikembangkannya skema *feature-level fusion* pada penelitian ini, sehingga informasi visual dari mata dan insang dapat dimanfaatkan secara bersama dalam satu proses klasifikasi.

Peneliti [13] melalui penelitian " A mobile hybrid *deep learning* approach for classifying 3D-like representations of Amazonian lizards" mengombinasikan beberapa varian MobileNet sebagai ekstraktor fitur dengan beberapa algoritma *machine learning*, termasuk SVM. Pada konfigurasi MobileNetV3-Small dengan linear SVM, artikel tersebut melaporkan akurasi 0,955 serta *precision*, recall, dan F1-score masing-masing 0,948. Rujukan ini digunakan untuk mendukung pemilihan pola hybrid *feature extractor* dan *classifier*.

Ringkasan peneltian-penelitian terdahulu tersebut beserta perbedaannya dengan penelitian ini disajikan pada Tabel 2.1.

Tabel 2.1 Penelitian Terdahulu

No	Peneliti	Objek dan Data	Metode	Hasil	Perbedaan dengan Penelitian Ini
1	[7]	Citra mata ikan bandeng, 154 citra 2 kelas (segar dan tidak segar)	Perbandingan CNN: VGG16, RestNet50, MobileNetV1, dan Xception	VGG16 memperoleh akurasi terbaik sebesar 97%	Hanya menggunakan citra mata ikan dan dua kelas kesegaran

No	Peneliti	Objek dan Data	Metode	Hasil	Perbedaan dengan Penelitian Ini
2	[8]	Citra kepala dan ekor ikan bandeng, 312 citra, 3 kelas (sangat segar, segar, dan tidak segar)	SSD untuk deteksi kepala dan ekor serta MobileNetV2 untuk klasifikasi	Akurasi keseluruhan sebesar 81,6%; akurasi per kelas masing-masing 97%, 70%, dan 80%	Menggunakan citra kepala dan ekor ikan secara utuh, bukan citra mata dan insang
3	[9]	Citra mata ikan bandeng, 200 citra asli (800 setelah augmentasi), 2 kelas segar dan tidak segar	Nilai piksel 64x64 yang diratakan (*flatten*) sebagai fitur, klasifikasi SVM kernel linear dan Polynomial	Akurasi tertinggi 94,17% (Polynomial, C = 0,1)	Hanya menggunakan citra mata dan dua kelas, tanpa ekstraktor fitur *deep learning* dan tanpa citra insang
4	[15]	Citra mata ikan, 150 citra pada beberapa interval waktu penyimpanan	*Cropping*, segmentasi, ekstraksi nilai RGB, dan klasifikasi menggunakan KNN	Akurasi tertinggi sebesar 93,33% pada K=1	Hanya menggunakan citra mata ikan dengan fitur warna RGB

No	Peneliti	Objek dan Data	Metode	Hasil	Perbedaan dengan Penelitian Ini
5	[16]	Citra mata dan insang ikan laut	Ekstraksi fitur HSV pada insang dan LBP pada mata, kemudian klasifikasi menggunakan KNN	Akurasi fitur HSV pada insang sebesar 90%, sedangkan fitur tekstur mata sebesar 85% (berdasarkan 45 kali pengujian untuk setiap metode)	Menggunakan fitur dan *classifier* yang berbeda pada setiap bagian ikan tanpa melakukan penggabungan fitur
6	[10]	Citra mata dan insang ikan mungkus	Naïve Bayes	Akurasi sebesar sekitar 66%	Citra mata dan insang diproses secara terpisah dan tidak membentuk satu representasi fitur gabungan

No	Peneliti	Objek dan Data	Metode	Hasil	Perbedaan dengan Penelitian Ini
7	[13]	Representasi *3D-like* kadal Amazon	Varian MobileNet sebagai ekstraktor fitur yang dikombinasikan dengan algoritma *machine learning*, termasuk SVM	MobileNetV3-Small dengan *linear SVM* memperoleh akurasi 0,955, serta *precision*, *recall*, dan F1-score sebesar 0,948	Objek penelitian bukan ikan, tetapi dapat menjadi rujukan untuk pola *hybrid* antara ekstraktor fitur dan *classifier*

Berdasarkan tinjauan terhadap penelitian-penelitian tersebut, dapat diidentifikasi bahwa penelitian pada ikan bandeng masih berfokus pada satu sumber citra (umumnya mata), sedangkan penelitian yang telah memanfaatkan citra mata dan insang secara bersama pada objek lain masih memiliki keterbasan berupa pemrosesan kedua citra secara terpisah. Oleh karena itu, penelitian ini mengusulkan pemanfaatan citra mata dan insang ikan bandeng yang sama secara bersamaan melalui skema *feature-level fusion* menggunakan MobileNetV3-Small sebagai ekstraktor fitur dan SVM sebagai algoritma klasifikasi, dengan tiga kategori kesegaran, yaitu Segar, Tidak Segar, dan Busuk.

2.2. Ikan

Ikan adalah hewan vertebrata berdarah dingin yang hidup di perairan dan bernapas menggunakan insang [17]. Ikan termasuk dalam filum Chordata dan memiliki struktur tubuh yang disesuaikan untuk kehidupan di air, seperti sirip untuk berenang dan tubuh yang aerodinamis. Ikan dapat ditemukan di berbagai habitat perairan, baik air tawar, air payau, maupun air laut, mulai dari sungai, danau, hingga perairan yang lebih kecil seperti rawa dan kolam. Bentuk tubuh ikan bervariasi, dari yang memanjang hingga

bulat, bergantung pada jenis dan adaptasinya terhadap lingkungan tempat ikan tersebut tinggal.

Sebagai salah satu sumber protein hewani, ikan memiliki kandungan protein yang mencapai 20%-30% dengan daya serap yang tinggi karena panjang serat proteinnya lebih singkat dibandingkan daging sapi dan ayam. Ikan juga mengandung asam amino esensial, asam lemak omega-3, vitamin, dan berbagai mineral yang bermanfaat bagi kesehatan tubuh manusia [1].

2.3. Ikan Bandeng

Ikan bandeng (*Chanos chanos*) merupakan salah satu komoditas perikanan Indonesia yang memiliki nilai ekonomi relatif tinggi dan banyak dimanfaatkan sebagai bahan pangan. Ikan bandeng juga memiliki berbagai bentuk diversifikasi produk, salah satunya adalah pengolahan menjadi otak-otak ikan bandeng [17]. Dalam bahasa Inggris ikan bandeng dikenal sebagai *milkfish.*

Ikan bandeng merupakan salah satu spesies ikan yang hidup di wilayah perairan payau dan dikenal luas, baik di dalam maupun luar negeri, karena cita rasanya yang khas. Kandungan protein hewani pada ikan ini lebih unggul dibandingkan protein nabati, karena memiliki asam amino yang lengkap serta struktur yang mirip dengan asam amino dalam tubuh manusia. Selain itu, ikan bandeng juga mengandung asam lemak omega-3, vitamin D, serta berbagai mineral penting seperti fosfor dan kalsium yang bermanfaat bagi kesehatan tubuh.

Secara morfologi, ikan bandeng memiliki tubuh yang ramping dan memanjang menyerupai torpedo, serta ekor bercabang yang menandakan kemampuannya sebagai perenang cepat. Kepalanya tidak bersisik, dengan mulut kecil di ujung rahang tanpa gigi dan lubang hidung yang terletak di depan mata. Mata bandeng dilapisi selaput bening (*subcutaneus),* sementara tubuhnya berwarna putih keperakan dengan punggung yang bergradasi biru kehitaman. Ikan bandeng termasuk jenis ikan *euryhaline,* yaitu mampu bertahan dalam berbagai tingkat salinitas. Bandeng dapat hidup di perairan samudra dengan kadar garam tinggi sehingga di tambak pesisir, bahkan dapat beradaptasi di air tawar setelah melalui proses aklimatisasi.

Kesegaran ikan merupakan salah satu faktor penting yang menentukan mutu, cita rasa, tekstur, dan kelayakan ikan untuk dikonsumsi. Penilaian kesegaran ikan pada umumnya dilakukan dengan mengamati karakteristik fisik seperti kondisi mata, warna insang, tekstur, dan aroma. Mata dan insang merupakan dua bagian tubuh ikan yang

menunjukkan perubahan karakteristik visual yang dapat diamati selama penurunan kesegaran, sehingga keduanya dipilih sebagai fokus pengamatan visual pada penelitian ini. Penelitian ini membagi tingkat kesegaran ikan bandeng ke dalam tiga kategori, yaitu Segar, Tidak Segar, dan Busuk, sebagai pengembangan dari penelitian terdahulu yang umumnya hanya menggunakan dua kategori.

2.4. Kesegaran Ikan Bandeng Berdasarkan Citra Mata

Mata merupakan salah satu indikator visual utama dalam penentuan tingkat kesegaran ikan. Perubahan pada mata dapat diamati dari kejernihan kornea, kilau, warna, dan bentuk bola mata. [18] menunjukkan bahwa citra mata dapat digunakan untuk memprediksi tingkat kesegaran ikan dengan metode Convolutional Neural Network. Pada Gambar 2.1 hingga Gambar 2.3 memperlihatkan perbedaan visual antara ketiga kategori kesegaran tersebut.



Gambar 2.1 Mata Ikan Bandeng Segar

Ciri visual mata ikan segar terlihat pada Gambar 2.1, jernih, menkilap, dan cembung (menonjol keluar), dengan warna bening atau sedikit kebiruan. Bola mata tampak bulat sempurna dengan pupil hitam yang jelas. Kondisi ini menandakan jaringan mata belum mengalami degradasi atau pembusukan, sehingga ikan masih layak dikonsumsi dan belum lama ditangkap.



Gambar 2.2 Mata Ikan Bandeng Tidak Segar

Pada gambar 2.2 ditampilkan contoh mata ikan bandeng dalam kategori Tidak Segar. Ciri visual yang tampak antara lain mata yang keruh dan kusam, cekung ke dalam, kehilangan kilau alami, serta bola mata yang tidak lagi bulat sempurna dan

cenderung berwarna keabu-abuan. Kondisi ini mengindikasikan bahwa ikan telah disimpan cukup lama, terpapar udara secara keberlanjutan, atau mulai memasuki tahap awal pembusukan.



Gambar 2.3 Mata Ikan Bandeng Busuk

Kategori busuk merupakan tahapan penurunan kesegaran yang lebih lanjut dibandingkan kategori Tidak Segar. Pada tahap ini, maka ikan umumnya menunjukkan kondisi yang jauh lebih parah, yaitu kornea sangat keruh dan berwarna kekuningan hingga kecokelatan, bola mata sangat cekung ke dalam akibat penyusutan jaringan, serta pupil yang tampak sangat buram atau bahkan sulit dibedakan dari bagian mata lainnya. Kondisi ini menunjukkan bahwa ikan telah memasuki tahap pembusukan lanjut, di mana kerusakan jaringan di sekitar mata semakin signifikan.

2.5. Kesegaran Ikan Bandeng Berdasarkan Citra Insang

Selain mata, insang juga menjadi indikator visual kesegaran ikan. Perubahan warna dan kondisi permukaan insang mencerminkan perubahan kualitas ikan selama penyimpanan. [19] menunjukkan bahwa citra insang dapat digunakan untuk mengidentifikasi kesegaran ikan dengan metode Deep Convolutional Neural Network, yang berarti informasi visual pada insang dapat diproses secara otomatis untuk mendukung identifikasi tersebut. Pada Gambar 2.4 hingga Gambar 2.6 memperlihatkan perbedaan visual insang ikan bandeng untuk masing-masing kategori kesegaran.



Gambar 2.4 Insang Ikan Bandeng Segar

Insang ikan bandeng dalam kondisi segar umumnya berwarna merah hingga merah tua merata, dengan lembaran-lembaran insang (*filamen*) yang tersusun rapi,

lembap, dan tidak berlendir berlebihan. Warna merah pada insang dapat menjadi salah satu karakteristik visual yang diamati dalam proses penilaian kesegaran ikan. Pada penelitian ini, karakteristik tersebut digunakan sebagai salah satu dasar pengamatan kondisi ikan dalam kategori segar.



Gambar 2.5 Insang Ikan Bandeng Tidak Segar

Pada kondisi Tidak Segar, warna insang mulai memudar dari merah cerah menjadi merah keruh hingga sedikit kecokelatan, disertai perubahan permukaan insang dan mulai terlihat lendir. Perubahan karakteristik visual tersebut dapat digunakan sebagai salah satu indikasi terjadinya penurunan kualitas ikan selama penyimpanan. Pada penelitian ini, perubahan warna dan kondisi permukaan insang digunakan sebagai salah satu dasar dalam menentukan kategori tidak segar.



Gambar 2.6 Insang Ikan Bandeng Busuk

Pada kondisi Busuk, warna insang berubah signifikan menjadi cokelat gelap hingga keabu-abuan. Kondisi permukaan insang juga dapat menunjukkan perubahan yang lebih lanjut, seperti peningkatan lendir dan perubahan tekstur. Karakteristik visual tersebut menunjukkan adanya penurunan kualitas ikan yang lebih lanjut.

2.6. Citra Digital

Citra merupakan gambaran dua dimensi dari suatu objek dalam dunia visual, sedangkan citra digital adalah gambar yang telah dikonversi menjadi data numerik sehingga dapat diproses oleh komputer [20]. Citra digital tersusun dari kumpulan piksel yang disusun dalam bentuk matriks dua dimensi, di mana setiap piksel

merepresentasikan nilai intensitas pada titik tertentu dengan koordinat awal (0,0). Fungsi intensitas piksel dalam citra digital dijelaskan melalui persamaan 2.1.

$$f(x,y) = I \tag{2.1}$$

Keterangan :

f(x,y) = nilai intensitas piksel

I = nilai grayscale atau komponen dari warna RGB

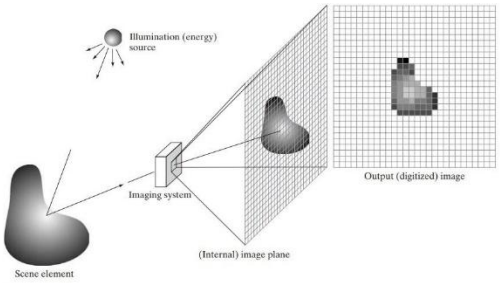
Apabila citra terdiri dari tiga saluran warna, maka nilai intensitasnya dapat diperluas sesuai dengan persamaan 2.2.

$$f(x,y) = [R(x,y), G(x,y), B(x,y)] \tag{2.2}$$

Persamaan 2.2 menjelaskan bahwa setiap piksel dalam citra memiliki posisi yang ditentukan oleh koordinat (x,y) dan memiliki nilai intensitas yang menentukan warnanya. Pada citra grayscale, setiap piksel memiliki intensitas yang bervariasi berdasarkan tingkat keabuan, mulai dari hitam hingga putih. Nilai intensitas dalam citra grayscale umumnya berada dalam rentang [0, 255], dengan amplitudo *I* = 0 untuk warna hitam, dan *I* = 255 untuk warna putih. Citra digital dapat direpresentasikan sebagai sebuah matriks berukuran M x N, yang terdiri atas M kolom dan N baris, di mana setiap titik perpotongan antara baris dan kolom tersebut sebagai piksel (*picture element*), sebagaimana ditunjukkan pada persamaan 2.3.

$$f(x,y) = \begin{bmatrix} f(0,0) & f(0,1) & \cdots & f(0,N-1) \\ f(1,0) & f(1,1) & \cdots & f(1,N-1) \\ \vdots & \vdots & \ddots & \vdots \\ f(M-1,0) & f(M-1,1) & \cdots & f(M-1,N-1) \end{bmatrix} \tag{2.3}$$

Setiap piksel memiliki dua parameter utama, yaitu koordinat posisi dan nilai intensitas atau warna. Nilai pada koordinat (x,y) dinyatakan sebagai f(x,y) yang merepresentasikan tingkat intensitas warna dari piksel pada titik tersebut. Dalam proses digitalisasi yang melibatkan tahap sampling dan kuantisasi, citra akan dibentuk menjadi matriks berukuran M x N, dengan M sebagai jumlah baris dan N sebagai jumlah kolom, serta G sebagai jumlah level keabuan yang dimiliki oleh piksel. Proses sampling citra analog ke citra digital ditampilkan pada gambar 2.7.



Gambar 2.7 Proses Sampling Citra

Merujuk pada Gambar 2.7, citra digital dapat direpresentasikan secara sistematis sebagai sebuah fungsi intensitas f(x,y), di mana x dan y menunjukkan koordinat posisi piksel dalam bentuk baris dan kolom. Nilai f(x,y) menggambarkan intensitas cahaya, tingkat keabuan, atau warna pada titik tertentu dalam citra tersebut. Citra digital sendiri memilki beragam jenis, di antaranya:

1. Citra Biner (Monokrom)

   Jumlah warna yang digunakan hanya terdiri dari dua, yaitu hitam dan putih. Untuk merepresentasikan kedua warna tersebut, diperlukan memori sebesar 1 bit.

2. Citra Abu-Abu (Grayscale)

   Jumlah warna yang dapat ditampilkan bergantung pada banyaknya bit yang dialokasikan di memori untuk merepresentasikan warna. Semakin besar jumlah bit yang tersedia, semakin halus gradasi warna yang dihasilkan.

3. Citra Warna (True Color)

   Setiap piksel pada citra berwarna merepresentasikan sebuah warna hasil perpaduan dari tiga komponen warna dasar, yaitu merah, hijau, dan biru. Masing-masing komponen warna ini disimpan dalam 1 byte (8 bit), sehingga memungkinkan pembentukan lebih dari 16 juta kombinasi warna. Format ini dikenal dengan istilah true color karena mampu merepresentasikan spektrum warna yang sangat luas.

2.7. Pengolahan Citra Digital

Pengolahan citra digital adalah bidang ilmu yang mempelajari teknik-teknik untuk memanipulasi gambar digital guna meningkatkan kualitas, memberikan informasi penting, bahkan mengubahnya menjadi bentuk yang lebih berguna [20]. Pengolahan citra digunakan di berbagai bidang, seperti keamanan, medis, dan pertanian. Menurut Kamus Besar Bahasa Indonesia (KBBI), “pengolahan” adalah

proses atau cara mengubah atau memperbaiki sesuatu menjadi lebih baik atau sempurna, sedangkan “citra” diartikan sebagai sumber gambar atau rupa.

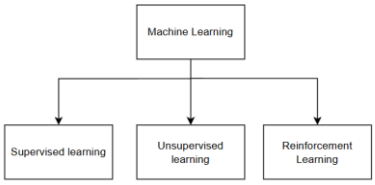
Proses pengolahan citra mencakup berbagai aspek, seperti peningkatan kontras gambar, perubahan warna, dan restorasi gambar. Pada penelitian ini, pengolahan citra digunakan pada tahap praproses (*preprocessing*) sebelum citra mata dan insang diekstraksi fiturnya menggunakan MobileNetV3-Small, misalnya melalui resizing, croppingm dan normalisasi nilai piksel.

Preprocessing citra merupakan tahap persiapan data yang dilakukan sebelum citra digunakan dalam proses ekstraksi fitur dan klasifikasi. Tahap ini bertujuan mengubah citra menjadi bentuk yang lebih sesuai dengan kebutuhan model serta mengurangi variasi yang tidak diperlukan. Preprocessing merupakan bagian dari pengolahan citra yang dapat mencakup beberapa proses, seperti penyesuaian ukuran citra, normaliasasi, dan transformasi citra [20].

Pada penelitia ini, preprocessing dilakukan terhadap citra mata dan insang ikan bandeng sebelum masuk ke tahap ekstraksi fitur menggunakan MobileNetV3-Small. Tahapan preprocessing yang digunakan meliputi resize citra, pembagian data, dan augmentasi data. Resize dilakukan untuk menyeragamkan ukuran citra agar sesuai dengan ukuran masukan MobileNetV3-Small. Pembagian data dilakukan dalam proses pelatihan dan pengujian model. Selanjutnya, augmentasi diterapkan pada data pengembangan untuk menambahn variasi citra dan membantu model mempelajari karakteristik visual yang lebih beragam.

2.8. *Machine Learning*

Machine Learning (ML) merupakan pendekatan komputasi yang memungkinkan sistem mempelajari pola atau hubungan dari data untuk menghasilkan prediksi maupun keputusan berdasarkan data yang telah dipelajari. Secara umum, paradigma pembelajaran dalam *machine learning* dapat dikelompokkan menjad supervised learning, unsupervised learning, dan reinforcement learning [21].



Gambar 2.8 Jenis-jenis *Machine Learning*

Teknik belajar dalam *machine learning* memiliki beberapa pendekatan seperti pada Gambar 2.8. Berikut beberapa di antaranya:

1. Supervised Learning

   Supervised learning menggunakan data pengembangan yang telah memiliki label. Model mempelajari hubungan antara data masukan dan label keluaran selama proses pelatihan, kemudian menggunakan hubungan tersebut untuk memprediksi label pada data yang belum diketahui. Pendekatan ini digunakan pada permasalahan klasifikasi dan regresi; pada klasifikasi, model menentukan kelas dari suatu data, sedangkan pada regresi model memprediksi suatu nilai keluaran [21].

   Beberapa algoritma yang termasuk dalam supervised learning antara lain Decision Tree, Random Forest, Support Vector Machine (SVM), dan berbagai model jaringan saraf [21]. Dalam penelitian ini, supervised learning digunakan pada tahap klasifikasi karena *dataset* memiliki label berupa tiga kategori kesegaran ikan bandeng, yaitu Segar, Tidak Segar, dan Busuk. Fitur hasil ekstraksi dari MobileNetV3-Small digunakan sebagai data masukan, sedangkan label kelas kesegaran digunakan sebagai target yang dipelajari oleh SVM.

2. Unsupervised Learning

   Berbeda dari supervised learning unsupervised learning, unsupervised learning bekerja pada data tanpa label. Tujuannya adalah menemukan pola, struktur, atau hubungan tertentu yang terdapat dalam data tanpa menggunakan label sebagai acuan pembelajaran. Salah satu penerapannya adalah clustering, yaitu pengelompokkan data berdasarkan karakteristik atau kemiripan tertentu [21].

3. Reinforcement Learning

   Reinforcement learning memungkinkan suatu agen mempelajari tindakan yang sesuai melalui interaksi dengan lingkungan. Agen menerima suatu keadaan (state), memilih tindakan (action), kemudian memperoleh umpan balik berupa reward atau penalti. Proses tersebut dilakukan secara berulang sehingga agen dapat mempelajari kebijakan (policy) berdasarkan hasil interaksi dengan lingkungannya [21].

2.9. *Deep Learning*

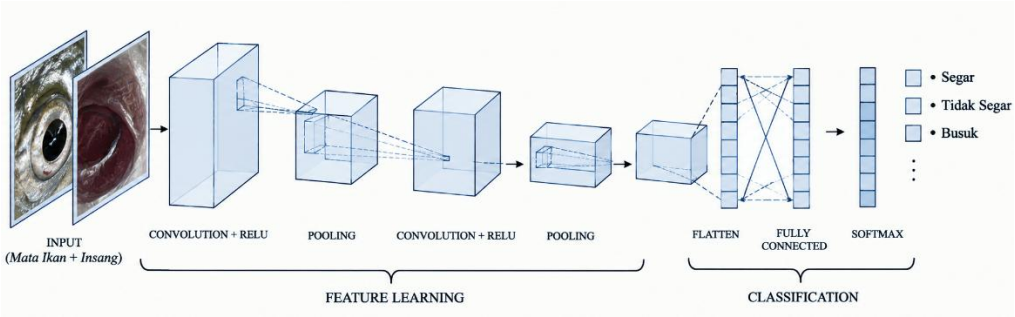
Deep Learning merupakan salah satu cabang dari *machine learning* yang berbasis pada penggunaan jaringan saraf tiruan (ANN), dan sering dianggap sebagai perkembangan lanjutan dari metode ANN [22]. Metode ini memungkinkan model komputasi yang terdiri dari beberapa lapisan pemrosesan untuk belajar mewakili data dalam berbagai level abstraksi. *Deep learning* digunakan dalam berbagai bidang, seperti pengenalan suara, pengenalan objek visual, serta domain lain seperti penemuan obat.

Deep learning mampu menemukan struktur yang kompleks dalam kumpulan data besar menggunakan algoritma *backpropagation* untuk menentukan cara mesin harus menyesuaikan parameter internalnya, yang digunakan untuk menghitung representasi di setiap lapisan berdasarkan representasi lapisan sebelumnya. Perbedaan utama antara Neural Network dan *deep learning* terletak pada jumlah lapisan tersembunyi, *deep learning* merupakan pendekatan pembelajaran mesin yang menggunakan jaringan saraf dengan banyak lapisan untuk mempelajari representasi data secara hierarkis. Berbagai arsitektur *deep learning* yang populer dan sering digunakan dalam penelitian antara lain Recurrent Neural Network (RNN), Long Short Term Memory (LSTM), dan Convolutional Neural Network (CNN).

2.10. Convolutional Neural Network (CNN)

Convolutional Neural Network (CNN) merupakan sebuah algoritma *deep learning* yang sangat umum digunakan [23]. Arsitektur CNN terdiri atas satu lapisan masukan (*input layer*), satu lapis keluaran (*output layer*), dan lapis tersembunyi (*hidden layer*). Lapisan tersembunyi ini umumnya mencakup *convolutional layer*, pooling, normalisasi, aktivasi reLu, *fully connected layer*, hingga *loss function* layer. Arsitektur CNN sendiri terdiri dari dua tahap utama, yaitu *Feature Learning* dan *Classification*.

Pada Gambar 2.9 ditampilkan ilustrasi arsitektur Convolutional Neural Network secara umum, yang menggambarkan alur pemrosesan citra masukan berupa citra mata dan citra insang ikan bandeng hingga dihasilkan keluaran berupa kelas kesegaran, yaitu Segar, Tidak Segar, dan Busuk.



Gambar 2.9 Arsitektur CNN

Berdasarkan Gambar 2.9, arsitektur CNN tersusun atas dua tahap utama, yaitu *Feature Learning* dan *Classification*. Pada tahap *Feature Learning*, citra masukan melewati beberapa kali proses convolutional dan *pooling* secara berurutan sehingga dihasilkan peta fitur yang merepresentasikan pola visual penting pada citra, seperti tepi, tekstur, dan bentuk objek. Peta fitur tersebut selanjutnya diproses pada tahap *Classification*, dimulai dari lapisan flatten yang mengubah peta fitur menjadi vektor satu dimensi, kemudian diteruskan ke lapisan fully connected, hingga akhirnya lapisan softmax menghasilkan nilai probabilitas untuk tiap kelas hingga model dapat menentukan kelas keluaran yang paling sesuai dengan citra yang dianalisis. Ketiga jenis lapisan yang berperan penting pada kedua tahap tersebut, yaitu *Convolutional Layer*, *Pooling* Layer, dan *Fully Connected Layer*, dijelaskan lebih lanjut pada subbab berikut.

2.10.1 *Feature Learning*

Feature learning merupakan tahap pada Convolutional Neural Network (CNN) yang bertujuan membentuk representasi fitur dari citra melalui serangkaian operasi pada jaringan. Pada tahap ini, citra masukan diproses melalui lapisan konvolusi, fungsi aktivasi, dan *pooling* untuk menghasilkan representasi fitur yang semakin abstrak dan informatif. Lapisan konvolusi berfungsi mengekstraksi lokal dari citra menggunakan filter atau kernel, sedangkan fungsi aktivasi memperkenalkan sifat nonlinear agar jaringan mampu mempelajari pola yang lebih kompleks. Selanjutnya, *pooling* digunakan untuk melakukan *downsampling* pada peta fitur sehingga ukuran representasi dan beban komputasi dapat dikurangi [23].

2.10.2 *Classification* CNN

Classification merupakan tahap yang bertujuan menentukan kelas suatu data berdasarkan representasi fitur yang telah diperoleh pada tahap *feature*

learning. Pada arsitektur CNN konvolusional, fitur yang telah diekstraksi dapat diteruskan ke lapisan fully connected dan *output layer* untuk menghasilkan prediksi kelas. Pada klasifikasi multikelas, fungsi softmax dapat digunakan untuk mengubah keluaran jaringan menjadi nilai probabilitas untuk setiap kelas [23].

Dalam penelitian ini, lapisan klasifikasi bawaan MobileNetV3-Small tidak digunakan. Representasi fitur berukuran 1x1x1024 dari citra mata dan citra insang diambil dari masing-masing cabang, kemudian digabungkan melalui *feature-level fusion* menggunakan *concatenation*. Vektor fitur gabungan tersebut selanjutnya digunakan sebagai masukan bagi Support Vector Machine (SVM) untuk melakukan klasifikasi ke dalam tiga kelas yaitu Segar, Tidak Segar, dan Busuk.

2.11. MobileNetV3-Small

MobileNetV3 merupakan arsitektur jaringan saraf ringan yang dikembangkan dari MobileNetV1 dan MobileNetV2 dengan tujuan meningkatkan efisiensi komputasi dan kemampuan ekstraksi fitur. Arsitektur ini memanfaatkan inverted residual dan depthwise separable convolution untuk mengurangi beban komputasi pada proses pengolahan citra. MobileNetV3 juga menggunakan modul Squeeze and Excitation (SE) dan fungsi aktivasi yang disesuaikan untuk meningkatkan efisiensi arsitektur [24].

Pada penelitian ini digunakan MobileNetV3-Small sebagai ekstraktor fitur karena memiliki arsitektur yang lebih ringan dan efisien. Beberapa istilah yang digunakan untuk menjelaskan struktur MobileNetV3-Small adalah sebagai berikut.

1. Exp Size (Expansion Size)

   Exp Size menunjukkan jumlah channel setelah proses perluasan (expansion) pada bottleneck block. Nilai ini menunjukkan ukuran representasi fitur yang digunakan pada bagian internal bottleneck block sebelum diteruskan ke tahap berikutnya.

2. SE (Squeeze and Excitation)

   SE merupakan modul yang digunakan untuk memberikan bobot pada setiap channel berdasarkan tingkat kepentingannya. Modul ini membantu jaringan memberikan perhatian lebih terhadap informasi fitur yang relevan dan mengurangi pengaruh fitur yang penting.

3. NL (Non-Linear Activation)

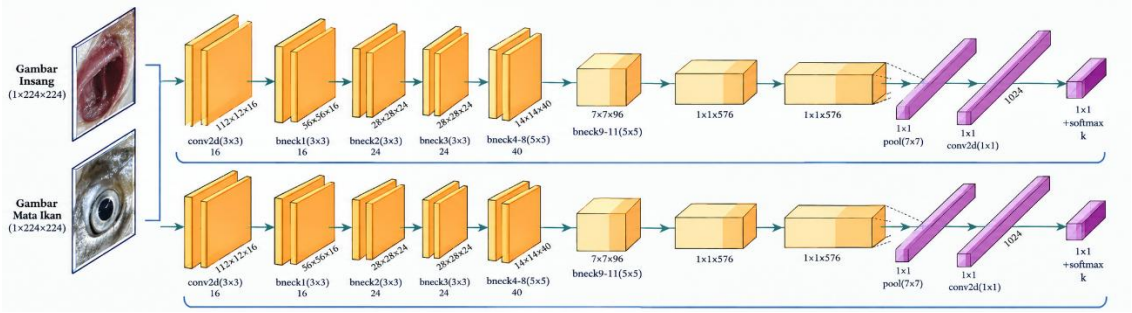
   NL menunjukkan fungsi aktivasi non-linear yang digunakan pada suatu lapisan. Pada MobileNetV3-Small digunakan beberapa fungsi aktivasi, salah satunya Hard-Swish (HS) dan ReLU (RE), untuk membantu jaringan mempelajari pola non-linear pada citra.

4. RE (ReLU)

   RE merupakan singkatan dari Rectified Linear Unit (ReLU), yaitu fungsi aktivasi yang menghasilkan nilai nol ketika masukan bernilai negatif dan mempertahankan nilai masukan ketika bernilai positif. Fungsi ini digunakan pada beberapa bottleneck block dalam MobileNetV3-Small.

5. S (Stride)

   S menunjukkan nilai stride yang digunakan pada operasi konvolusi atau bottleneck block. Stride menentukan besar perpindahan filter saat melakukan proses konvolusi dan mempengaruhi perubahan ukuran spasial *feature map*. Nilai stride yang lebih besar dapat menyebabkan ukuran spasial *feature map* menjadi lebih kecil.



Gambar 2.10 Arsitektur MobileNetV3-Small

Pada Gambar 2.10 menunjukkan arsitektur MobileNetV3-Small yang digunakan sebagai dasar ekstraksi fitur. Arsitektur tersebut terdiri atas lapisan konvolusi dan beberapa bottleneck block yang memanfaatkan depthwise separable convolution, modul Squeeze and Excitation (SE), serta fungsi aktivasi Hard-Swish (HS) dan ReLU (RE). Dalam penelitian ini, MobileNetV3-Small digunakan pada citra mata dan citra insang sebagai ekstraktor fitur, sedangkan lapisan klasifikasi bawaan MobileNetV3-Small tidak digunakan karena hasil ekstraksi fitur selanjutnya diproses menggunakan *feature-level fusion* dan Support Vector Machine (SVM). Rincian

penerapan arsitektur MobileNetV3-Small dalam penelitian ini dijelaskan lebih lanjut pada Bab III.

2.12. *Feature-Level Fusion*

Feature-level fusion merupakan pendekatan penggabungan informasi yang telah dilakukan setelah fitur dari masing-masing sumber data berhasil diekstraksi, tetapi sebelum proses klasifikasi akhir dilakukan. Pada pendekatan ini, fitur yang berasal dari beberapa sumber informasi digabungkan menjadi satu representasi sehingga informasi dari masing-masing sumber dapat digunakan secara bersama dalam proses klasifikasi. Pendekatan ini banyak dipakai dalam sistem multimodal dari beberapa sumber dipertahankan sebelum diteruskan ke tahap berikutnya [23].

Salah satu metode sederhana yang dapat digunakan untuk melakukan *feature-level fusion* adalah *concatenation*. *Concatenation* dilakukan dengan menyusun beberapa vektor fitur menjadi satu vektor fitur yang lebih panjang, sehingga informasi dari masing-masing sumber tetap dipertahankan dalam suatu representasi gabungan sebelum digunakan oleh *classifier*. Pada penggabungan fitur multimodal, *concatenation* banyak digunakan karena dapat menggabungkan representasi fitur secara langsung [25].

Pada penelitian ini, *feature-level fusion* diterapkan pada dua sumber citra, yaitu citra mata dan citra insang yang berasal dari ikan bandeng yang sama. Masing-masing citra diproses menggunakan arsitektur MobileNetV3-Small secara terpisah untuk memperoleh representasi fitur. Fitur dari citra mata menghasilkan vektor fitur berukuran 1x1x1024, sedangkan fitur dari citra insang juga menghasilkan vektor fitur berukuran 1x1x1024. Kedua vektor tersebut selanjutnya digabungkan menggunakan operasi *concatenation* sehingga menghasilkan satu vektor fitur gabungan berukuran 1x1x2048. Representasi gabungan tersebut kemudian digunakan sebagai masukan bagi Support Vector Machine (SVM) untuk menghasilkan satu keputusan klasifikasi terhadap pasangan citra yang berasal dari satu ekor ikan yang sama. Proses penggabungan dapat dirumuskan sebagai berikut:

$$F = \left[F_{\text{mata}}; F_{\text{insang}}\right] \tag{2.4}$$

Keterangan:

F = vektor fitur gabungan berukuran 1x1x2048

F_{mata} = vektor fitur hasil ekstraksi MobileNetV3-Small dari citra mata, berukuran 1x1x1024

F_{insang} = vektor fitur hasil ekstraksi MobileNetV3-Small dari citra insang, berukuran 1x1x1024

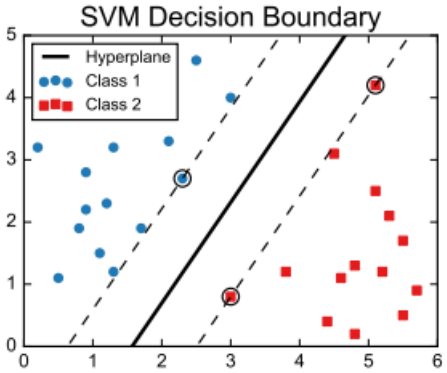
[;] = operator penggabungan (*concatenation*) antar vektor

Vektor fitur gabungan F inilah yang selanjutnya digunakan sebagai masukan bagi algoritma SVM untuk menghasilkan satu keputusan klasifikasi kesegaran bagi setiap pasangan citra mata dan insang yang berasal dari satu ekor ikan yang sama. Dengan pendekatan ini, informasi visual dari mata dan insang tidak lagi diperlakukan sebagai dua sumber data yang menghasilkan keputusan secara independen, melainkan sebagai dua informasi yang saling melengkapi dalam merepresentasikan satu objek ikan yang sama, sebagaimana ditunjukkan pada precedent penggunaan kombinasi ekstraktor fitur berbasis *deep learning* dengan *classifier machine learning* pada penelitian LizardNet [13].

2.13. Arsitektur SVM

Support Vector Machine (SVM) adalah teknik yang cukup baru yang digunakan untuk melakukan prediksi dalam kasus regresi maupun klasifikasi [14]. Algoritma ini bekerja dengan mencari hyperplane optimal yang mampu memisahkan kelas-kelas dalam suatu ruang fitur dengan margin terbesar, seperti yang dapat digambarkan pada ilustrasi berikut.

Untuk klasifikasi tiga kelas, penelitian ini menguji dua strategi multi-class yang tersedia pada implementasi SVM, yaitu One-vs-Rest (OvR) dan One-vs-One (OvO). Jenis kernel dan parameter yang relevan kemudian diuji pada data pelatihan. Model terbaik ditentukan berdasarkan data validasi dan tidak dipilih berdasarkan data uji final.



Gambar 2.11 Ilustrasi SVM

Ilustrasi pada Gambar 2.11 menjelaskan terkait sejumlah pola yang termasuk dalam dua kelas data berbeda, yakni +1 dan -1. Data pada kelas -1 direpresentasikan

dengan simbol lingkaran, sedangkan data pada kelas +1 ditandai dengan simbol persegi. Garis pemisah di SVM disebut hyperlane, dan data yang berada paling dekat dengan hyperlane disebut support vectors. Jarak antara hyperlane dengan support vectors disebut margin, yang harus dimaksimalkan untuk meningkatkan generalisasi model. Hyperplane dalam SVM didefinisikan sebagai persamaan 2.5.

$$w \cdot x + b = 0 \tag{2.5}$$

Keterangan:

w = vektor bobot

x = vektor fitur

b = bias

Jika data termasuk dalam kelas positif (+1), maka posisi data terhadap hyperplane harus memenuhi persamaan 2.6.

$$w \cdot x + b \geq 1 \tag{2.6}$$

Sebaliknya jika data termasuk dalam kelas negatif (-1), maka posisi data harus memenuhi persamaan 2.7.

$$w \cdot x + b \leq -1 \tag{2.7}$$

SVM berusaha mencari w dan b yang menghasilkan margin maksimum antar kelas-kelas yang ada. Margin adalah jarak antara hyperplane dengan titik terdekat dari masing-masing kelas (support vectors). Tujuan SVM adalah mencari margin terbesar, yang dihitung sebagaimana persamaan 2.8.

$$\text{margin} = \frac{1}{\|w\|} \tag{2.8}$$

Untuk mendapatkan margin terbesar, SVM menyelesaikan optimasi berikut pada persamaan 2.9.

$$\min_{w,b} \frac{1}{2}\|w\|^2 \tag{2.9}$$

Dengan syarat sebagaimana persamaan 2.10.

$$y_i(w \cdot x_i + b) \geq 1, \quad \forall i \tag{2.10}$$

Keterangan:

y_i = label kelas (+1 atau -1)

x_i = data ke-i

Persamaan 2.10 merupakan constraint yang digunakan untuk memastikan bahwa hyperlane yang dihasilkan memiliki jarak maksimal terhadap data dari kedua kelas, baik positif maupun negatif, serta menjaga stabilitas, dalam pemisahan antara

kelas. SVM memiliki beberapa jenis kernel, di antaranya kernel linear, kernel polynomial, kernel Gaussian Radial Basis Function (RBF), dan kernel sigmoid. SVM linear diterapkan untuk membedakan data yang dapat dipisahkan secara linear, yaitu ketika dua kelas data dapat dipisahkan menggunakan satu garis lurus atau hyperlane.

Sebaliknya, SVM Non-linear diterapkan pada data dengan pola yang kompleks atau tidak beraturan, di mana pemisahan tidak dapat dilakukan hanya dengan garis lurus. Untuk mengatasi hal ini, SVM memanfaatkan fungsi kernel guna memetakan data ke dalam ruang berdimensi lebih tinggi, sehingga pola pemisahan menjadi lebih terlihat. Pada penelitian ini, SVM menerima masukan berupa vektor fitur gabungan berukuran 1x1x2048 hasil *feature-level fusion* (lihat subbab 2.11) untuk mengklasifikasikan kesegaran ikan bandeng ke dalam tiga kelas (Segar, Tidak Segar, dan Busuk) menggunakan skema multi-class, misalnya one-vs-rest atau one-vs-one. Berikut adalah persamaan yang digunakan untuk masing-masing kernel.

1. Kernel Linear

$$K(x_i, x_j) = x_i \cdot x_j \tag{2.11}$$

Keterangan:

$K(x_i, x_j)$ = fungsi kernel antara x_i dan x_j

x_i = vektor fitur data ke-i

x_j = vektor fitur data ke-j

$\cdot$ = operasi perkalian titik

2. Kernel RBF

$$K(x_i, x_j) = \exp\left(-\gamma \|x_i - x_j\|^2\right) \tag{2.12}$$

Keterangan:

$K(x_i, x_j)$ = fungsi kernel antara x_i dan x_j

x_i = vektor fitur data ke-i

x_j = vektor fitur data ke-j

γ = parameter yang mengatur jarak antar data

exp = fungsi eksponensial

$\| x_i - x_j \|^2$ = kuadrat jarak Euclidean antara vektor x_i dan x_j

3. Kernel Sigmoid

$$K(x_i, x_j) = \tanh(\alpha x_i \cdot x_j + c) \quad (2.13)$$

Keterangan:

$K(x_i, x_j)$ = fungsi kernel antara x_i dan x_j

x_i = vektor fitur data ke-i

x_j = vektor fitur data ke-j

α = parameter skala kernel

c = konstanta

tanh = fungsi hiperbolik tangen

2.14. *Confusion Matrix*

Confusion matrix merupakan teknik yang digunakan untuk menilai performa suatu model klasifikasi [26]. Secara umum, matriks ini membandingkan hasil prediksi model dengan label asli dari data. *Confusion matrix* juga berperan dalam menghitung berbagai matriks evaluasi, seperti akurasi (*accuracy*), presisi (*precision*), recall, dan skor F1 (F1-score).

Berbeda dengan penelitian lainnya yang menggunakan *confusion matrix* berukuran 2x2 karena hanya memiliki dua kategori kesegaran (Segar dan Tidak Segar), penelitian ini menggunakan tiga kategori kesegaran (Segar, Tidak Segar, dan Busuk) sehingga *confusion matrix* yang digunakan berukuran 3x3, sebagaimana pada tabel 2.2

Tabel 2.2 Confusion Matrix

		Prediksi		
		Segar	Tidak Segar	Busuk
Aktual	Segar	TP_1	E_{12}	E_{13}
	Tidak Segar	E_{21}	TP_2	E_{23}
	Busuk	E_{31}	E_{32}	TP_3

Berdasarkan Tabel 2.2, sel-sel pada diagonal utama (TP_1, TP_2, TP_3) menunjukkan jumlah data yang diprediksi benar sesuai kelas aktualnya untuk masing-masing kelas Segar, Tidak Segar, dan Busuk, sedangkan sel-sel di luar diagonal (E_{12}, E_{13}, dan seterusnya) menunjukkan jumlah kesalahan klasifikasi (mis*classification*) antar kelas. Untuk menghitung metrik evaluasi pada kasus multi-kelas, nilai True Positive (TP), False Positive (FP), False Negative (FN), dan True Negative (TN)

dihitung untuk setiap kelas secara terpisah menggunakan pendekatan one-vs-rest, dengan penjelasan sebagai berikut:

1. True Positive (TP) suatu kelas menunjukkan jumlah data pada kelas tersebut yang diprediksi benar sesuai label aslinya (nilai pada sel diagonal)
2. False Positive (FP) suatu kelas menunjukkan jumlah data dari kelas lain yang salah diprediksi sebagai kelas tersebut (jumlah nilai pada kolom kelas tersebut, selain sel diagonal)
3. False Negative (FN) suatu kelas menunjukkan jumlah data pada kelas tersebut yang salah diprediksi sebagai kelas lain (jumlah nilai pada baris kelas tersebut, selain sel diagonal)
4. True Negative (TN) suatu kelas menunjukkan jumlah dari kelas lain yang benar diprediksi bukan sebagai kelas tersebut (seluruh sel di luar baris dan kolom kelas tersebut.

2.15. Metrik Performa

Evaluasi performa model merupakan salah satu langkah penting dalam membangun model *machine learning* yang efektif dan memiliki akurasi tinggi. Metrik performa adalah sekelompok ukuran atau nilai yang digunakan untuk mengevaluasi kualitas maupun kinerja model. Metrik performa yang digunakan adalah *accuracy*, *precision*, *recall*, dan *F1*-score [27]. Karena penelitian ini menggunakan tiga kelas kesegaran (Segar, Tidak Segar, dan Busuk), *precision*, *recall*, dan *F1*-score dihitung terlebih dahulu untuk setiap kelas, kemudian dirata-rata menggunakan pendekatan *macro-average* agar setiap kelas memiliki kontribusi yang setara terhadap nilai akhir metrik, tidak bergantung pada jumlah pada masing-masing kelas.

2.15.1. Akurasi

Akurasi merupakan salah satu metrik evaluasi yang digunakan guna mengukur seberapa baik suatu model klasifikasi memprediksi kelas yang benar dari sebuah data. Akurasi dihitung dengan membagi jumlah prediksi yang benar dengan jumlah total prediksi; semakin tinggi nilainya, semakin baik kinerja model tersebut. Pada kasus multi-kelas, akurasi dihitung dengan menjumlahkan seluruh True Positive dari setiap kelas kemudian dibagi dengan jumlah total data, sebagaimana persamaan 2.14.

$$\text{Akurasi} = \frac{\sum TP_i}{\text{Jumlah Data}} \tag{2.14}$$

Keterangan:

ΣTP_i = jumlah data yang diprediksi benar pada seluruh kelas (Segar, Tidak Segar, dan Busuk)

2.15.2. Presisi

Presisi biasa disebut sebagai nilai prediksi positif yang merupakan rasio antara jumlah instance yang relevan dengan semua instance yang diprediksi. Dalam masalah klasifikasi multi-kelas, presisi dihitung untuk setiap kelas dengan cara membagi jumlah True Positive (jumlah instance yang benar diberi label seabagai kelas tersebut) dengan jumlah instance yang diberi label seagai kelas tersebut (jumlah True Positive dan False Postive), sebagaimana persamaan 2.15.

$$\text{Presisi}_i = \frac{TP_i}{TP_i + FP_i} \tag{2.15}$$

2.15.3. *Recall*

Recall diartikan sebagai rasio antara jumlah True Positive dan total elemen yang benar-benar termasuk dalam kelas tersebut. Total elemen tersebut terdiri dari True Positive dan False Negative, yang seharusnya dilabeli sebagai milik kelas tersebut tetapi salah dilabeli sebagai milik kelas lain. Untuk mendapatkan nilai *recall* pada setiap kelas, dilakukan perhitungan dengan rumus sebagaimana persamaan 2.16.

$$\text{Recall}_i = \frac{TP_i}{TP_i + FN_i} \tag{2.16}$$

2.15.4. F1-Score

F1-Score dapat diartikan sebagai rata-rata antara presisi dan *recall*, dengan tujuan untuk memberikan penilaian yang seimbang antara kedua metrik tersebut. F1-Score memiliki nilai maksimum yakni 1,0 yang menunjukkan kinerja presisi dan *recall* yang sempurna, sementara niai minimumnya yakni 0 jika presisi atau *recall* bernilai nol. Untuk mendapatkan nilai F1-Score pada tiap kelas, dilakukan perhitungan dengan rumus sebagaimana persamaan 2.17.

$$F1_i = \frac{2 \times (\text{Presisi}_i \times \text{Recall}_i)}{\text{Presisi}_i + \text{Recall}_i} \tag{2.17}$$

Karena presisi, *recall*, dan F1-score pada persamaan 2.15 hingga 2.17 dihitung untuk setiap kelas (i = Segar, Tidak Segar, dan Busuk), maka diperlukan satu nilai akhir yang merepresentasikan performa model secara keseluruhan. Nilai akhir tersebut diperoleh melalui pendekatan *macro-average*, yaitu dengan merata-rata nilai metrik nilai dari seluruh kelas secara setara (tanpa memperhitungkan proporsi jumlah data pada setiap kelas), sebagaimana dirumuskan secara umum pada persamaan 2.18.

$$M_{\text{macro}} = \frac{1}{k} \times \sum_{i=1}^{k} M_i \tag{2.18}$$

Keterangan:

M_{macro} = nilai metrik rata-rata (*macro-average*); dapat berupa $\text{Presisi}_{\text{macro}}$, $Recall_{\text{macro}}$, maupun F1_{macro} dengan mensubstitusikan M sesuai metrik yang dihitung.

k = jumlah kelas kesegaran (pada penelitian ini, k = 3, yaitu Segar, Tidak Segar, dan Busuk)

M_i = nilai metrik (Presisi, *Recall*, atau F1-Score) pada kelas ke-i

Sebagai contoh, apabila M pada persamaan 2.18 disubstitusikan dengan nilai pada persamaan 2.15 dari ketiga kelas, maka hasilnya $\text{Presisi}_{\text{macro}}$ yang merepresentasikan presisi rata-rata model secara keseluruhan. Prinsip yang sama berlaku untuk menghitung $Recall_{\text{macro}}$ dan F1_{macro}.

2.16. Flask

Flask merupakan *lightweight web application framework* berbasis Python yang digunakan untuk membangun aplikasi web [28]. *Framework* ini memiliki pendekatan yang minimalis, sehingga memudahkan pengembang dalam merancang aplikasi web secara cepat tanpa memerlukan konfigurasi yang kompleks. Flask didudukung oleh dua pustaka eksternal utama, yakni WSGI Toolkit sebagai antarmuka server dan Jinja2 sebagai template engine untuk pengelolaan tampilan web.



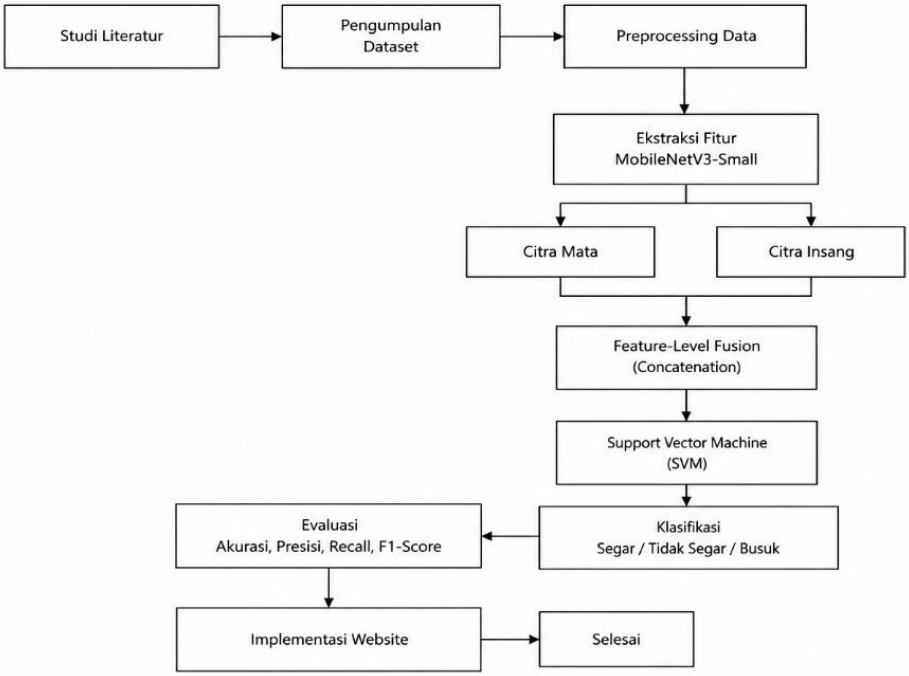
Gambar 2.12 Flask

Flask dikategorikan sebagai *microframework*, yang artinya tidak bergantung pada pustaka-pustaka tertentu untuk dapat digunakan. Meskipun ukurannya ringan, Flask tetap memberikan fleksibilitas bagi pengembang untuk memperluas fungsionalitas aplikasi melalui berbagai ekstensi pihak ketiga. *Framework* ini menyediakan fitur-fitur dasar seperti sistem *routing*, rendering template, dan pengelolaan sesi. Selain itu, Flask juga mendukung penambahan fitur tambahan seperti autentikasi, koneksi ke basis data, serta pengembangan API. Karena fleksibilitas dan kesederhanannya, Flask banyak dimanfaatkan dalam pengembangan proyek skala kecil hingga menengah, termasuk sebagai *backend* untuk aplikasi yang berkaitan dengan *machine learning* dan kecerdasan buatan (AI). Pada penelitian ini, Flask direncanakan digunakan sebagai *backend* untuk membangun antarmuka web sederhana memungkinkan model klasifikasi kesegaran ikan bandeng (MobileNetV3-Small + SVM) diakses dan diuji melalui unggahan citra mata dan insang oleh pengguna.

BAB III
METODOLOGI

3.1. Metode Penelitian

Penelitian ini dilaksanakan melalui beberapa tahapan yang disusun secara sistematis untuk mengembangkan sistem klasifikasi kesegaran ikan bandeng berdasarkan citra mata dan citra insang. Tahapan penelitian meliputi studi literatur, pengumpulan data, *preprocessing* data, ekstraksi fitur menggunakan MobileNetV3-Small, penggabungan fitur (*feature-level fusion*), klasifikasi menggunakan Support Vector Machine (SVM), evaluasi model, serta implementasi sistem berbasis *website*. Alur tahapan penelitian ditampilkan pada Gambar 3.1.



Gambar 3.1 Alur Penelitian

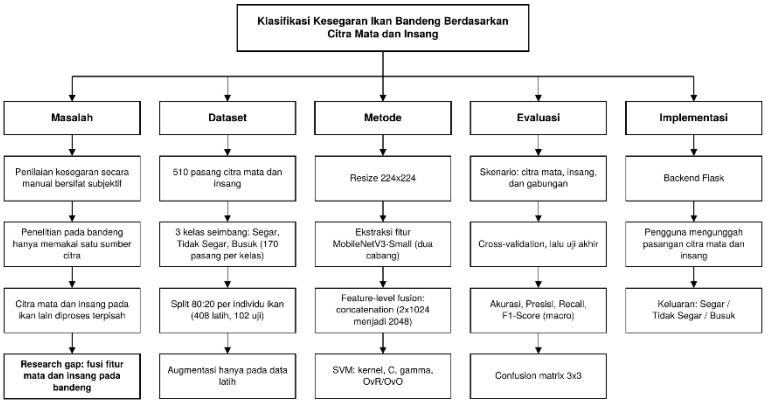
Berdasarkan Gambar 3.1, penelitian diawali dengan studi literatur untuk memperoleh landasan teori dan penelitian terdahulu yang berkaitan dengan klasifikasi kesegaran ikan, pengolahan citra MobileNetV3-Small, *feature-level fusion*, dan SVM. Tahap berikutnya adalah pengumpulan data berupa pasangan citra mata dan citra insang ikan bandeng yang berasal dari individu ikan yang sama pada tiga kategori kesegaran, yaitu Segar, Tidak Segar, dan Busuk.

Data yang diperoleh kemudian melalui tahap *preprocessing* yang meliputi *resize* citra, pembagian data, dan augmentasi data. Setelah *preprocessing*, citra mata dan citra insang diproses secara terpisah menggunakan dua cabang MobileNetV3-

Small yang memiliki arsitektur identik untuk menghasilkan vektor fitur dari masing-masing citra. Kedua vektor fitur tersebut kemudian digabungkan menggunakan *feature-level fusion* melalui operasi *concatenation*.

Vektor fitur gabungan selanjutnya digunakan sebagai masukan bagi SVM untuk melakukan klasifikasi ke dalam tiga kelas kesegaran. Model yang telah dilatih kemudian dievaluasi menggunakan metrik akurasi, presisi, *recall*, dan F1-Score. Setelah model diperoleh, model diintegrasikan ke dalam *website* agar pengguna dapat mengunggah pasangan citra mata dan insang untuk memperoleh hasil klasifikasi kesegaran ikan bandeng.

Selain alur tahapan pada Gambar 3.1, ringkasan keseluruhan penelitian ini juga divisualisasikan dalam bentuk peta pikiran (*mind map*) pada Gambar 3.2. Peta pikiran tersebut terdiri atas lima cabang utama yang berpusat pada topik klasifikasi kesegaran ikan bandeng berdasarkan citra mata dan insang, yaitu masalah, dataset, metode, evaluasi, dan implementasi.



Gambar 3.2 Mind Map

Cabang masalah menggambarkan latar belakang penelitian, yaitu penilaian kesegaran secara manual yang bersifat subjektif, penelitian pada ikan bandeng masih memanfaatkan satu sumber citra, serta pemrosesan citra mata dan insang pada ikan lain yang dilakukan secara terpisah. Ketiganya menjadi celah penelitian ini, yaitu penggabungan fitur citra mata dan insang pada ikan bandeng.

Cabang dataset berisi 510 pasang citra mata dan insang dengan tiga kelas seimbang (segar, tidak segar, dan busuk), pembagian data 80:20 berdasarkan individu ikan menjadi 408 pasang data pengembangan dan 102 pasang data uji, serta

augmentasi yang hanya diterapkan pada data latih. Cabang metode memuat tahapan resize citra menjadi 224x224 piksel, ekstraksi fitur menggunakan dua cabang MobileNetV3-Small, feature-level fusion melalui concatenation (2x1024 menjadi 2048), dan klasifikasi menggunakan SVM dengan variasi kernel, nilai C, gamma, serta strategi OvR dan OvO.

Pada cabang evaluasi, skenario pengujian mencakup citra mata, citra insang, dan gabungan keduanya, dengan cross-validation pada data pengembangan dan uji akhir pada data uji. Metrik yang digunakan adalah akurasi, presisi, recall, dan F1-score, serta confusion matrix berukuran 3x3. Cabang implementasi menjelaskan penerapan model pada aplikasi web berbasis Flask, tempat pengguna mengunggah pasangan citra mata dan insang untuk memperoleh keluaran kelas segar, tidak segar, dan busuk.

3.2. Studi Literatur

Tahapan studi literatur dilakukan melalui pencarian dan pemahaman terhadap berbagai sumber referensi, seperti artikel ilmiah, jurnal, dan penelitian terdahulu yang mempunyai keterkaitan dengan topik penelitian. Sumber-sumber tersebut digunakan untuk membangun landasan teori yang sesuai dan mendukung pelaksanaan penelitian, antara lain terkait pengolahan citra digital, algoritma Convolutional Neural Network (CNN), arsitektur MobileNetV3-Small, algoritma Support Vector Machine (SVM), konsep *feature-level fusion*, serta metrik performa model.

3.3. Pengumpulan *Dataset*

Pengumpulan data mencakup kegiatan pengambilan citra mata dan citra insang ikan bandeng yang terdiri dari tingkat kesegaran, yaitu Segar, Tidak Segar, dan Busuk. Pengambilan data dilakukan secara langsung dengan mendokumentasikan bagian mata dan insang ikan bandeng pada masing-masing kondisi kesegaran.

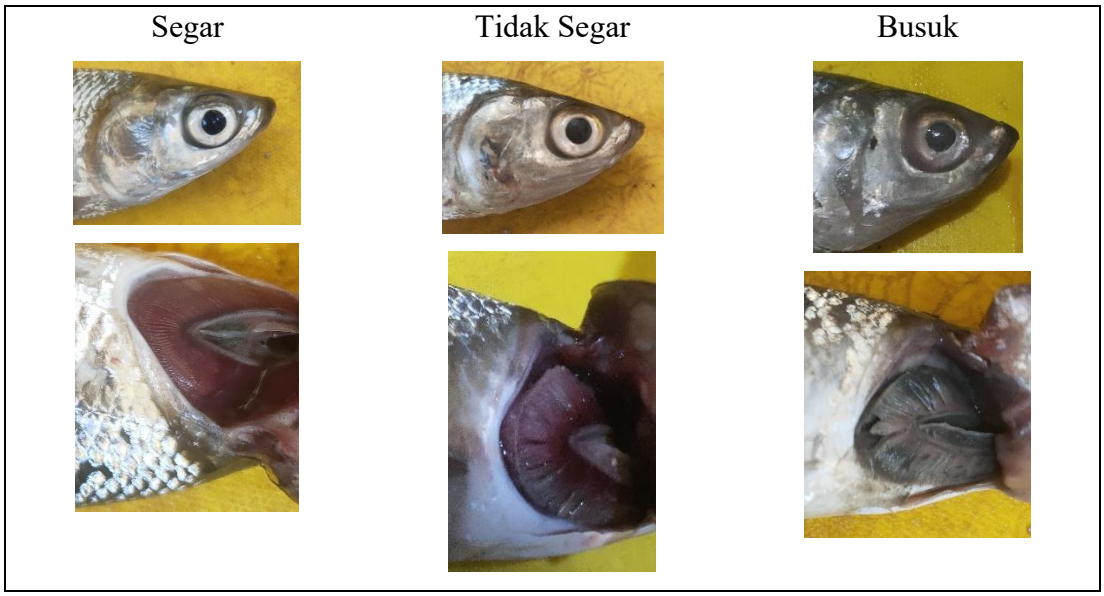
Citra mata dan insang selanjutnya dikelompokkan berdasarkan kelas kesegaran yang sama. Pada pembentukan sampel multimodal, satu citra mata dan satu citra insang dengan kelas kesegaran yang sama dipasangkan untuk kemudian diproses menggunakan dua cabang MobileNetV3-Small dan digabungkan melalui *feature-level fusion*.

Jumlah pasangan citra yang digunakan untuk setiap kelas ditetapkan secara seimbang. Rincian jumlah citra dan pasangan yang digunakan dalam penelitian ditampilkan pada Tabel 3.1.

Table 3.1 Jumlah Data per Kelas

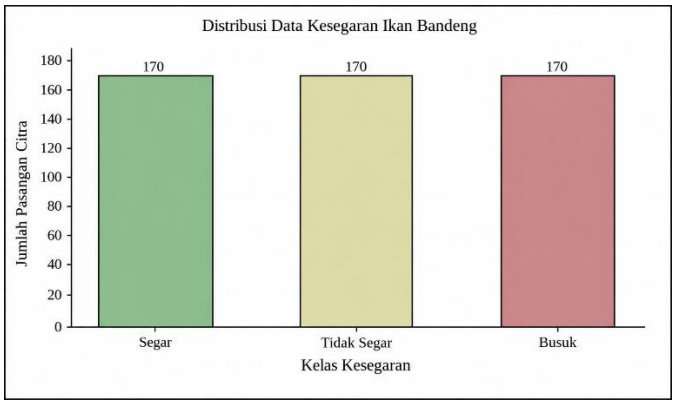
Kelas Kesegaran	Jumlah Citra Mata	Jumlah Citra Insang	Jumlah Pasangan CItra
Segar	170	170	170
Tidak Segar	170	170	170
Busuk	170	170	170
Total	510	510	510

Contoh sampel data untuk masing-masing kategori kesegaran ditampilkan pada Gambar 3.2.



Gambar 3.3 Sample Data

Pada Gambar 3.3 ditampilkan sampe data dari ketiga kondisi kesegaran yang diteliti. Data tersebut digunakan untuk melatih dan menguji model klasifikasi, dengan perbedaan visual pada bagian mata dan insang ikan sebagai acuan utama dalam menentukan tingkat kesegarannya.

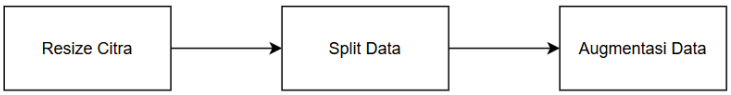


Gambar 3.4 Ilustrasi Persebaran Data

Gambar 3.4 merupakan ilustrasi persebaran data yang diperoleh, yang menunjukkan bahwa data pada ketiga kelas telah seimbang (*balanced*), yaitu masing-masing 170 pasang citra per kelas. Meskipun demikian, jumlah data mentah yang dikumpulkan masih tergolong terbatas, sehingga pada tahap praproses selanjutnya diterapkan teknik augmentasi data untuk memperkaya variasi data pengembangan dan membantu model belajar secara lebih optimal, sebagaimana dijelaskan pada subbab 3.4.

3.4 *Preprocessing* Data

Pada tahap *preprocessing*, data berupa pasangan citra mata dan citra insang ikan bandeng dipersiapkan agar memiliki ukuran dan format yang sesuai sebelum digunakan pada tahap ekstraksi fitur dan klasifikasi. *Preprocessing* pada penelitian ini terdiri atas tiga tahapan, yaitu *resize* citra, pembagian data (*split data*), dan augmentasi data. Ketiga tahapan tersebut dilakukan secara berurutan sebagaimana ditampilkan pada Gambar 3.5.



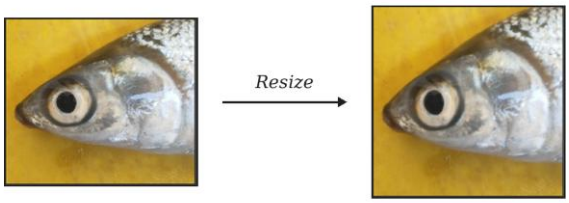
Gambar 3.5 Alur *Preprocessing* Data

Augmentasi data dilakukan setelah proses pembagian data dan hanya diterapkan pada data pengembangan yang digunakan dalam proses pelatihan. Urutan tersebut digunakan untuk mencegah terjadinya *data leakage*, yaitu kondisi ketika variasi hasil augmentasi dari suatu citra asli dapat tersebar ke data pengembangan dan data uji akhir sehingga menyebabkan evaluasi performa model menjadi tidak representatif. Selama *preprocessing*, pasangan citra mata dan citra insang dari individu

ikan yang sama tetap dipertahankan sebagai satu pasangan dan menggunakan label kesegaran yang sama.

1. ***Resize***

   Tahap *resize* dilakukan untuk menyeragamkan ukuran seluruh citra mata dan citra insang menjadi 224x224 piksel. Ukuran tersebut disesuaikan dengan ukuran masukan yang digunakan oleh arsitektur MobileNetV3-Small. Karena setiap sampel penelitian terdiri atas satu citra mata dan satu citra insang dari individu ikan yang sama, kedua citra pada setiap pasangan diubah ke ukuran yang sama sebelum diproses pada masing-masing cabang MobileNetV3-Small.

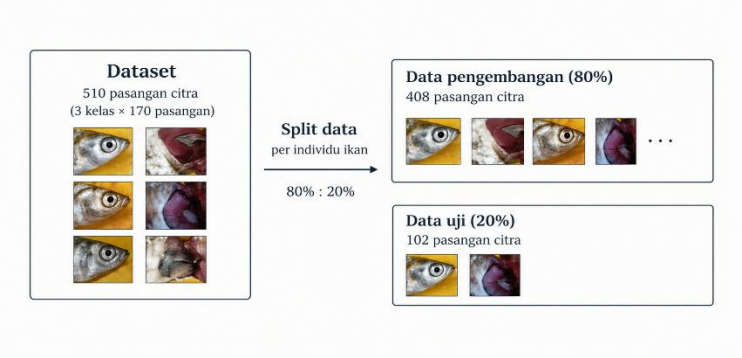


Gambar 3.6 Ilustrasi Resize

   Setelah proses *resize*, setiap citra memiliki tiga kanal warna sehingga ukuran masukan yang digunakan pada model adalah 224x224x3. Dengan ukuran yang seragam, citra mata dan citra insang dapat diproses secara konsisten pada tahap ekstraksi fitur.

2. ***Split Data***

   Setelah seluruh citra memiliki ukuran yang seragam, *dataset* dibagi menjadi 80% data pengembangan dan 20% data uji. Pembagian dilakukan berdasarkan individu ikan, bukan berdasarkan citra secara terpisah. Dengan demikian, citra mata dan citra insang yang berasal dari individu ikan yang sama selalu ditempatkan pada subset yang sama. Hal ini dilakukan untuk mencegah citra dari individu ikan yang sama muncul pada data pengembangan dan data uji secara bersamaan.



Gambar 3.7 Ilustrasi Split Data

Dataset penelitian terdiri atas 510 pasangan citra, dengan masing-masing kelas memiliki 170 pasangan citra. Berdasarkan pembagian 80% dan 20%, diperoleh 408 pasangan citra pada data pengembangan dan 102 pasangan citra pada data uji.

Data pengembangan selanjutnya digunakan dalam proses *cross-validation* untuk pelatihan model dan pemilihan *hyperparameter*. Pada setiap iterasi *cross-validation*, sebagian data pengembangan digunakan sebagai data pelatihan, sedangkan lainnya digunakan sebagai data validasi. Sementara itu, data uji disimpan dan tidak digunakan dalam proses pelatihan maupun pemilihan konfigurasi model. Data uji hanya digunakan pada tahap evaluasi akhir untuk mengukur performa model terhadap data yang tidak digunakan selama proses pengembangan.

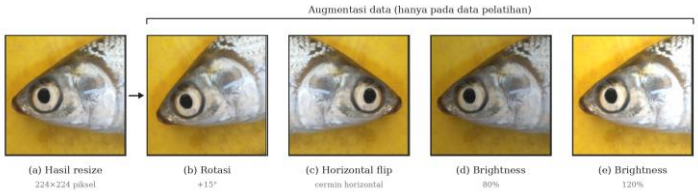
3. Augmentasi

Augmentasi data diterapkan hanya pada data pelatihan pada setiap iterasi *cross-validation*. Data validasi tidak akan mengalami augmentasi sehingga evaluasi pada setiap iterasi tetap menggunakan data yang tidak dimodifikasi. Data uji juga tidak mengalami augmentasi dan hanya digunakan pada tahap evaluasi akhir. Tahap ini dilakukan untuk memperbanyak variasi citra dan membantu model mempelajari karakteristik visual yang lebih beragam serta mengurangi risiko *overfitting*. Teknik augmentasi yang digunakan terdiri atas:

1) Rotasi, yaitu memutar citra pada rentang ±15–20 untuk memberikan variasi orientasi citra.
2) *Horizontal flip*, yaitu membalik citra setara horizontal untuk menghasilkan variasi posisi objek.

3) Penyesuaian *brightness*, yaitu mengubah tingkat kecerahan citra pada rentang 80%-120% dari citra asli untuk memberikan variasi kondisi pencahayaan.

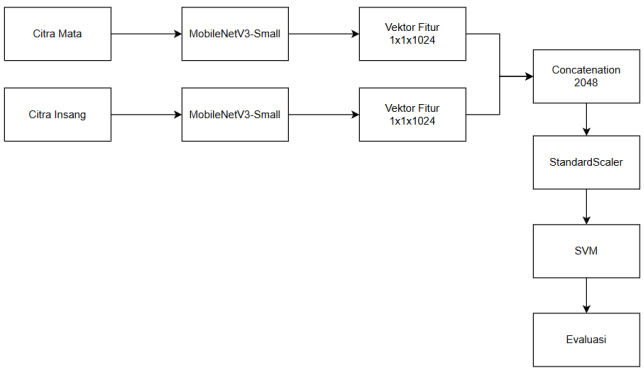
Rentang augmentasi dipilih secara konservatif karena warna dan tingkat kejernihan pada citra mata dan insang merupakan karakteristik visual yang digunakan sebagai informasi dalam proses klasifikasi kesegaran. Augmentasi yang terlalu ekstrem berisiko mengubah karakteristik visual tersebut sehingga dapat mengurangi informasi yang relevan untuk proses klasifikasi.



Gambar 3.8 Ilustrasi Augmentasi

3.5. MobileNetV3-Small dan Support Vector Machine (SVM)

Penelitian ini menggunakan MobileNetV3-Small sebagai ekstraktor fitur dan Support Vector Machine (SVM) sebagai *classifier* dalam klasifikasi kesegaran ikan bandeng. Citra mata dan citra insang diproses secara terpisah menggunakan dua cabang MobileNetV3-Small dengan arsitektur identik. Fitur yang dihasilkan dari kedua cabang kemudian digabungkan menggunakan *feature-level fusion* melalui operasi *concatenation*. Vektor fitur gabungan selanjutnya digunakan sebagai masukan bagi SVM untuk melakukan klasifikasi ke dalam tiga kelas kesegaran. Alur penerapan MobileNetV3-Small dan SVM ditampilkan pada Gambar 3.9.



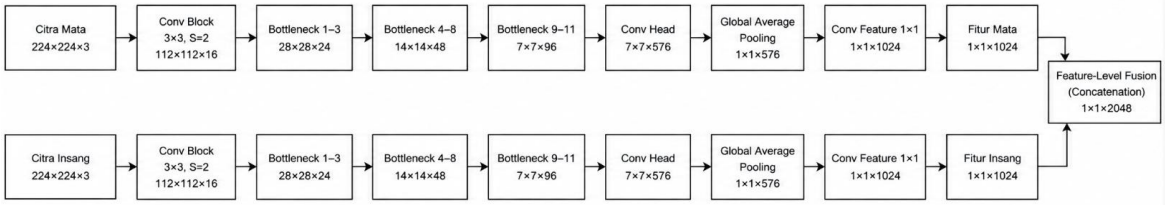
Gambar 3.9 MobileNetV3-Small dan SVM

Pada Gambar 3.9 ditampilkan alur model yang dimulai dengan memasukkan citra mata dan citra insang yang telah melalui tahap praproses ke dalam dua cabang

MobileNetV3-Small secara paralel. Kedua cabang tersebut memiliki arsitektur internal yang identik, namun proses secara terpisah sehingga masing-masing menghasilkan vektor fitur berukuran 1x1x1024. Kedua vektor fitur tersebut selanjutnya digabungkan melalui operasi *concatenation* menjadi satu vektor fitur gabungan berukuran 2048, yang kemudian digunakan sebagai masukan bagi algoritma SVM untuk melakukan klasifikasi bagi algoritma SVM untuk melakukan klasifikasi ke dalam tiga kelas kesegaran. Hasil klasifikasi tersebut selanjutnya dievaluasi menggunakan metrik performa model, sebagaimana dijelaskan pada subbab berikutnya.

3.5.1 Arsitektur MobileNetV3-Small

Pada tahap ini, MobileNetV3-Small digunakan sebagai ekstraktor fitur pada dua sumber citra, yaitu citra mata dan citra insang ikan bandeng. Kedua citra diproses secara terpisah menggunakan dua cabang MobileNetV3-Small yang memiliki arsitektur dan konfigurasi yang identik. Alur ekstraksi fitur pada kedua cabang ditampilkan pada Gambar 3.10, sedangkan konfigurasi setiap lapisan pada Tabel 3.2.



Gambar 3.10 Alur MobileNetV3-Small

Berdasarkan Gambar 3.10, proses ekstraksi fitur dimulai dari citra mata dan citra insang yang telah melalui tahap *preprocessing*. Setiap citra memiliki ukuran masuk 224x224x3, kemudian diproses melalui arsitektur MobileNetV3-Small secara terpisah. Proses diawali dengan Conv Block menggunakan konvolusi 3x3 dengan stride 2 yang menghasilkan representasi berukuran 112x112x16. Selanjutnya, citra melewati rangkaian bottleneck block yang terdiri atas Bottleneck 1 hingga Bottleneck 11. Rangkaian tersebut melakukan transformasi ukuran dan representasi fitur secara bertahap hingga menghasilkan *feature map* berukuran 7x7x96. Rincian expansion size, jumlah output channel, penggunaan Squeeze and Excitation (SE), fungsi aktivasi, dan stride pada setiap bottleneck block ditampilkan pada Tabel 3.2.

Table 3.2 Arsitektur MobileNetV3-Small

Input	Operator	Exp size	#out	SE	NL	S
$224^2 \times 3$	conv2d, 3x3	-	16	-	HS	2
$112^2 \times 16$	bneck, 3x3	16	16	✓	RE	2
$56^2 \times 16$	bneck, 3x3	72	24	-	RE	2
$28^2 \times 24$	bneck, 3x3	88	24	-	RE	1
$28^2 \times 24$	bneck, 5x5	96	40	✓	HS	2
$14^2 \times 40$	bneck, 5x5	240	40	✓	HS	1
$14^2 \times 40$	bneck, 5x5	240	40	✓	HS	1
$14^2 \times 40$	bneck, 5x5	120	48	✓	HS	1
$14^2 \times 48$	bneck, 5x5	144	48	✓	HS	1
$14^2 \times 48$	bneck, 5x5	288	96	✓	HS	2
$7^2 \times 96$	bneck, 5x5	576	96	✓	HS	1
$7^2 \times 96$	bneck, 5x5	576	96	✓	HS	1
$7^2 \times 96$	conv2d, 1x1	-	576	✓	HS	1
$7^2 \times 576$	pool, 7x7	-	-	-	-	1
$1^2 \times 576$	conv2d 1×1, NBN	-	1024	0	HS	1
$1^2 \times 1024$	conv2d 1×1, NBN	-	K	-	-	1

1. ***Conv Block*** **-** Layer pertama berupa Conv2D berukuran kernel 3x3 dengan stride 2. Layer ini menerima citra masukan berupa 224x224x3 dan mengubahnya menjadi 112x112x16. Aktivasi yang digunakan adalah Hard-Swish (HS).
2. ***Bottleneck 1*** – Blok bottleneck kernel 3x3 dengan ukuran ekspansi 16, output channel 16, menggunakan modul SE dan aktivasi ReLU (RE), serta stride 2 sehingga menghasilkan output 56x56x16.

3. ***Bottleneck 2*** – Blok bottleneck kernel 3x3 dengan ekspansi 72, output channel 24, tanpa SE aktivasi ReLU, stride 2, menghasilkan output 28x28x24.
4. ***Bottleneck 3*** – Blok bottleneck kernel 3x3 dengan ekspansi 88, output channel tetap 24, tanpa SE, aktivasi ReLU, stride 1, sehingga ukuran spasial tetap 28x28.
5. ***Bottleneck 4*** – Blok bottleneck kernel 5x5 dengan ekspansi 96, output channel 40, menggunakan SE dan aktivasi Hard-Swish, stride 2, menghasilkan output 14x14x40.
6. ***Bottleneck 5*** – Blok bottleneck kernel 5x5 dengan ekspansi 240, output channel tetap 40, SE aktif aktivasi Hard-Swish, stride 1.
7. ***Bottleneck 6*** – Blok bottleneck kernel 5x5, ekspansi 240, output channel 40, SE aktif, aktivasi Hard-Swish, stride 1.
8. ***Bottleneck 7*** - Blok bottleneck kernel 5x5 dengan ekspansi 120, output channel 48, SE aktif, aktivasi Hard-Swish, stride 1, ukuran spasial 14x14
9. ***Bottleneck 8*** – Blok bottleneck kernel 5x5 dengan ekspansi 144, output channel tetap 48, SE aktif, aktivasi Hard-Swish, stride 1.
10. ***Bottleneck 9*** – Blok bottleneck kernel 5x5 dengan ekspansi 288, output channel 96, SE aktif, Hard-Swish, stride 2, menghasilkan output 7x7x96.
11. ***Bottleneck 10*** – Blok bottleneck kernel 5x5 dengan ekspansi 576, output channel tetap 96, SE aktif, aktivasi Hard-Swish, stride 1.
12. ***Bottleneck 11*** – Konfigurasi serupa bottleneck 10, kernel 5x5, ekspansi 576, output channel 96, SE aktif, aktivasi Hard-Swish, stride 1.
13. ***Conv Head*** – Konvolusi 1x1 yang menggabungkan seluruh informasi fitur dari layer sebelumnya, mengubah 96 channel menjadi 576 channel, dengan SE aktif dan aktivasi Hard-Swish, ukuran output tetap 7x7x576.
14. ***Global Average Pooling*** – Lapisan *pooling* 7x7 yang mereduksi dimensi spasial menjadi satu nilai per channel, menghasilkan vektor berukuran 1x1x576.

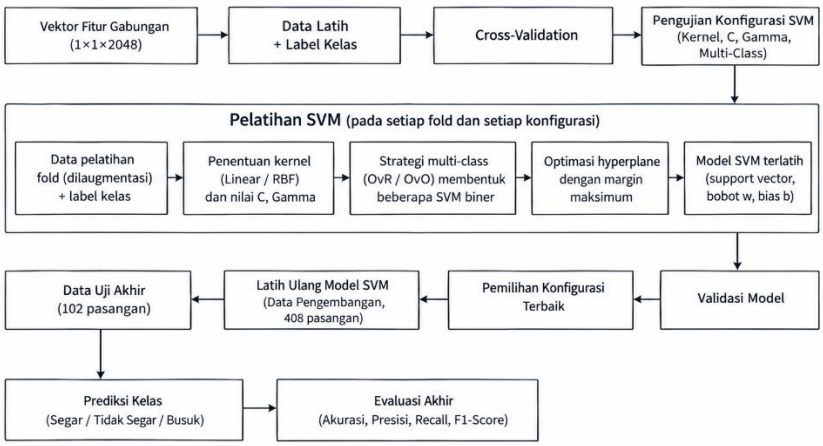
15. ***Conv Feature (1x1x1024)*** – Konvolusi 1x1 tanpa batch normalization (NBN) dengan aktivasi Hard-Swish yang mengubah vektor 1x1x576 menjadi vektor fitur akhir berukuran 1x1x1024. Vektor inilah yang digunakan sebagai representasi fitur dari masing-masing cabang pada tahap *feature-level fusion*.

Setelah seluruh bottleneck block selesai diproses, *feature map* diteruskan ke Conv Head menggunakan konvolusi 1x1 sehingga diperoleh representasi berukuran 7x7x576. Selanjutnya, dilakukan *Global Average Pooling* untuk mereduksi dimensi spasial sehingga diperoleh representasi menggunakan konvolusi 1x1x576. Representasi tersebut kemudian diproses menggunakan konvolusi 1x1 pada Conv Feature sehingga menghasilkan vektor fitur akhir berukuran 1x1x1024.

MobileNetV3-Small pada penelitian ini hanya digunakan sampai tahap ekstraksi fitur. Lapisan klasifikasi bawaan MobileNetV3-Small yang menghasilkan keluaran kelas menggunakan fungsi Softmax tidak digunakan. Vektor fitur berukuran 1x1x1024 dari cabang citra mata dan cabang citra insang selanjutnya digunakan pada tahap *feature-level fusion*. Kedua vektor fitur tersebut digabungkan menggunakan operasi *concatenation* sehingga menghasilkan satu vektor fitur gabungan berukuran 1x1x2048. Vektor fitur gabungan tersebut kemudian digunakan sebagai masukan bagi Support Vector Machine (SVM) untuk melakukan klasifikasi ke dalam tiga kelas kesegaran, yaitu Segar, Tidak Segar, dan Busuk.

3.5.2 Support Vector Machine (SVM)

Vektor fitur gabungan berukuran 1x1x2048 yang dihasilkan melalui tahap *feature-level fusion* digunakan sebagai masukan bagi algoritma Support Vector Machine (SVM) untuk melakukan klasifikasi kesegaran ikan bandeng. Setiap vektor fitur memiliki label kelas yang menunjukkan kategori kesegaran, yaitu Segar, Tidak Segar, dan Busuk. Alur klasifikasi menggunakan SVM ditampilkan pada Gambar 3.11.



Gambar 3.11 Alur SVM

Berdasarkan Gambar 3.11, proses klasifikasi dimulai dari vektor fitur gabungan hasil *feature-level fusion*. Vektor fitur tersebut digunakan sebagai masukan pada proses pengembangan model SVM bersama dengan label kelas masing-masing data. Karena penelitian ini menggunakan tiga kelas kesegaran, proses klasifikasi menggunakan strategi multi-class, yaitu One-vs-Rest (OvR) dan One-vs-One (OvO).

Sebelum proses pelatihan dilakukan, beberapa konfigurasi SVM diuji untuk memperoleh model yang sesuai. Konfigurasi yang diuji meliputi jenis kernel Linear dan Radial Basis Function (RBF) sebesar 0,1, 0,01, dan 0,001, serta strategi multi-class OvR dan OvO. Variasi tersebut digunakan untuk membentuk beberapa kombinasi konfigurasi SVM yang akan dibandingkan dalam proses *cross-validation*.

Pada tahap *cross-validation*, data pengembangan dibagi ke dalam beberapa bagian (fold). Pada setiap iterasi, fold digunakan untuk melatih model SVM, sedangkan fold lainnya digunakan sebagai data validasi. Proses tersebut dilakukan secara berulang pada setiap konfigurasi *hyperparameter* yang diuji. Augmentasi hanya diterapkan pada data pelatihan pada masing-masing iterasi, sedangkan data validasi tidak mengalami augmentasi. Hasil evaluasi pada data validasi tidak mengalami augmentasi. Hasil evaluasi pada data validasi digunakan untuk menentukan konfigurasi SVM yang digunakan pada tahap selanjutnya. Konfigurasi terbaik dipilih berdasarkan hasil evaluasi pada data validasi dan tidak menggunakan data uji dalam proses pemilihannya.

Setelah konfigurasi terbaik diperoleh, model SVM dilatih kembali menggunakan seluruh 408 pasangan data pengembangan dengan konfigurasi tersebut. Model yang telah dilatih kemudian digunakan untuk melakukan prediksi terhadap 102 pasangan data uji yang sebelumnya tidak digunakan dalam proses pelatihan maupun pemilihan konfigurasi. Hasil prediksi pada data uji selanjutnya dibandingkan dengan label sebenarnya untuk memperoleh nilai performa model menggunakan metrik akurasi, presisi, *recall*, dan F1-score.

3.5.3 Simulasi Perhitungan Manual

Bagian ini menyajikan simulasi perhitungan manual untuk melengkapi penjelasan pada subbab 3.5.1 dan 3.5.2, dengan menerapkan persamaan-persamaan yang telah dijelaskan pada Bab II terhadap contoh angka yang disederhanakan. Vektor fitur yang digunakan pada simulasi ini berukuran jauh lebih kecil dibandingkan vektor fitur asli (1024 elemen per citra, atau 2048 elemen setelah fusion) dan bersifat ilustratif, untuk memperjelas tahapan perhitungan. Pada implementasi sebenarnya, seluruh nilai tersebut diperoleh secara otomatis melalui proses *forward-pass* MobileNetV3-Small dan pelatihan SVM menggunakan pustaka scikit-learn.

a) Simulasi *Feature-Level Fusion* (Persamaan 2.4)

Misalkan sepasang citra mata dan insang baru diproses melalui dua cabang MobileNetV3-Small, dan hasil ekstraksi fiturnya disederhanakan menjadi 4 elemen per citra sebagaimana ditampilkan pada Tabel 3.3.

Table 3.3 Vektor Fitur Ilustratif Citra Mata dan Insang

Vektor	Elemen 1	Elemen 2	Elemen 3	Elemen 4
F_{mata}	0,82	0,35	0,61	0,90
F_{insang}	0,58	0,44	0,73	0,21

Berdasarkan persamaan 2.4, kedua vektor tersebut digabungkan melalui *concatenation* sehingga diperoleh vektor fitur gabungan F sebagai berikut:

$$F = \begin{bmatrix} F_{mata} \\ F_{insang} \end{bmatrix} = (0{,}82;\ 0{,}35;\ 0{,}61;\ 0{,}90;\ 0{,}58;\ 0{,}44;\ 0{,}73;\ 0{,}21)$$

Vektor F berukuran 8 elemen ini secara sederhana mewakili konsep vektor fitur gabungan berukuran 2048 elemen (1024+1024)

pada implementasi sebenarnya, yang selanjutnya digunakan sebagai masukan bagi algoritma SVM.

b) Simulasi Perhitungan Kernel SVM (Persamaan 2.11 dan 2.12)

Untuk mengilustrasikan penerapan kernel Linear dan RBF sebagaimana diuji pada Tabel 3.5, vektor F hasil bagian (a) diperlakukan sebagai data yang akan diklasifikasikan, serta digunakan sebuah vektor fitur pendukung (support vector) ilustratif yang mewakili pola kelas segar hasil pelatihan, dilambangkan Fsv.Nilai F, Fsv, dan vektor bobot w (digunakan pada bagian c) ditampilkan pada Tabel 3.4.

Table 3.4 Vektor Fitur Gabungan (F), Vektor Fitur Pendukung (Fsv) dan Vektor Bobot (w)

Elemen ke-	F	Fsv	W
1	0,82	0,75	1,2
2	0,35	0,30	-0,8
3	0,61	0,55	1,0
4	0,90	0,85	0,9
5	0,58	0,50	-0,5
6	0,44	0,40	-0,6
7	0,73	0,65	0,7
8	0,21	0,15	-1,1

Berdasarkan persamaan 2.11, kernel Linear dihitung sebagai hasil kali antara F dan Fsv:

$$K(F, F_{sv}) = F \cdot F_{sv}$$

$$= (0{,}82 \times 0{,}75) + (0{,}35 \times 0{,}30) + (0{,}61 \times 0{,}55) + (0{,}90 \times 0{,}85) + (0{,}58 \times 0{,}50) + (0{,}44 \times 0{,}40) + (0{,}73 \times 0{,}65) + (0{,}21 \times 0{,}15)$$

$$= 0{,}6150 + 0{,}1050 + 0{,}3355 + 0{,}7650 + 0{,}2900 + 0{,}1760 + 0{,}4745 + 0{,}0315$$

$$= 2{,}7925$$

Berdasakan persamaan 2.12, kernel RBF memerlukan kuadrat jarak Eulidean antara F dan Fsv, dengan nilai $\gamma = 0{,}01$

$$\|F - F_{sv}\|^2 = (0{,}82 - 0{,}75)^2 + (0{,}35 - 0{,}30)^2 + (0{,}61 - 0{,}55)^2 + (0{,}90 - 0{,}85)^2 + (0{,}58 - 0{,}50)^2 + (0{,}44 - 0{,}40)^2 + (0{,}73 - 0{,}65)^2 + (0{,}21 - 0{,}15)^2 = 0{,}0049 + 0{,}0025 + 0{,}0036 + 0{,}0025 + 0{,}0064 + 0{,}0016 + 0{,}0064 + 0{,}0036 = 0{,}0315$$

$K(F, F_{sv}) = \exp(-\gamma\|F - F_{sv}\|^2) = \exp(-0{,}01 \times 0{,}0315) = \exp(-0{,}000315) \approx 0{,}9997$

Nilai kernel RBF yang mendekati 1 menunjukkan bahwa F dan Fsv memiliki kemiripan tinggi pada ruang fitur ilustratif ini, sesuai dengan persamaan 2.12 di mana semakin kecil jarak antar vektor maka nilai kernel semakin mendekati 1.

c) Simulasi Keputusan Klasifikasi SVM Linear (Persamaan 2.5-2.7)

Untuk mengilustrasikan tahap akhir klasifikasi, digunakan SVM Linear dengan vektor bobot w (Tabel 3.4) dan bias = -0,35. Nilai w dan b berikut merupakan parameter ilustratif yang diasumsikan sebagai hasil pelatihan; pada implementasi sebenarnya, nilai w dan b diperoleh secara otomatis melalui proses optimasi menggunakan pustaka scikit-learn sebagaimana dijelaskan pada subbab 3.5.2, bukan dihitung secara manual.

$$w \cdot F = (1{,}2 \times 0{,}82) + (-0{,}8 \times 0{,}35) + (1{,}0 \times 0{,}61) + (0{,}9 \times 0{,}90) + (-0{,}5 \times 0{,}58) + (-0{,}6 \times 0{,}44) + (0{,}7 \times 0{,}73) + (-1{,}1 \times 0{,}21)$$

$$= 0{,}984 + (-0{,}280) + 0{,}610 + 0{,}810 + (-0{,}290) + (-0{,}264) + 0{,}511 + (-0{,}231) = 1{,}850$$

$$f(F) = w \cdot F + b = 1{,}850 + (-0{,}35) = 1{,}500$$

Berdasarkan persamaan 2.6, karena f(F) = 1,5 ≥ 1, maka F memenuhi syarat kelas positif (+1), sehingga pasangan citra mata dan insang tersebut diklasifikasikan ke dalam kelas segar.

Simulasi di atas menunjukkan salah satu contoh proses klasifikasi biner (Segar terhadap Busuk) sebagai bagian dari skema multi-class One-vs-One (OvO) yang digunakan pada penelitian ini (subbab 3.5.2). Prosedur perhitungan yang sama berlaku untuk

pasangan kelas lainnya (Segar-Tidak Segar dan Tidak Segar-Busuk), serta variasi sumber citra (mata saja, insang saja, atau gabungan mata-insang) serta variasi konfigurasi kernel dan *hyperparameter* SVM lainnya sebagaimana dirancang pada Tabel 3.5. Pada implementasi sebenarnya, seluruh proses dilakukan secara otomatis menggunakan pustaka scikit-learn terhadap 510 pasangan citra hasil pengumpulan data.

3.6. Skenario Pengujian

Skenario penelitian merupakan rancangan yang digunakan untuk melakukan pengujian model, memilih konfigurasi *hyperparameter*, menganalisis hasil yang diperoleh, serta menarik kesimpulan berdasarkan tujuan penelitian. Pada penelitian ini, MobileNetV3-Small digunakan sebagai *feature extractor* menggunakan bobot *pretrained* tanpa proses *fine-tuning*. Data pengembangan digunakan dalam proses *cross-validation* untuk menentukan konfigurasi model dan *hyperparameter* Support Vector Machine (SVM), sedangkan data uji hanya digunakan untuk evaluasi performa akhir. Skenario pengujian meliputi perbandingan sumber citra yang digunakan, yaitu citra mata, citra insang, dan gabungan citra mata-insang melalui *feature-level fusion*, serta pengujian konfigurasi kernel dan *hyperparameter* SVM. Skenario penelitian yang digunakan dapat dilihat pada Tabel 3.5.

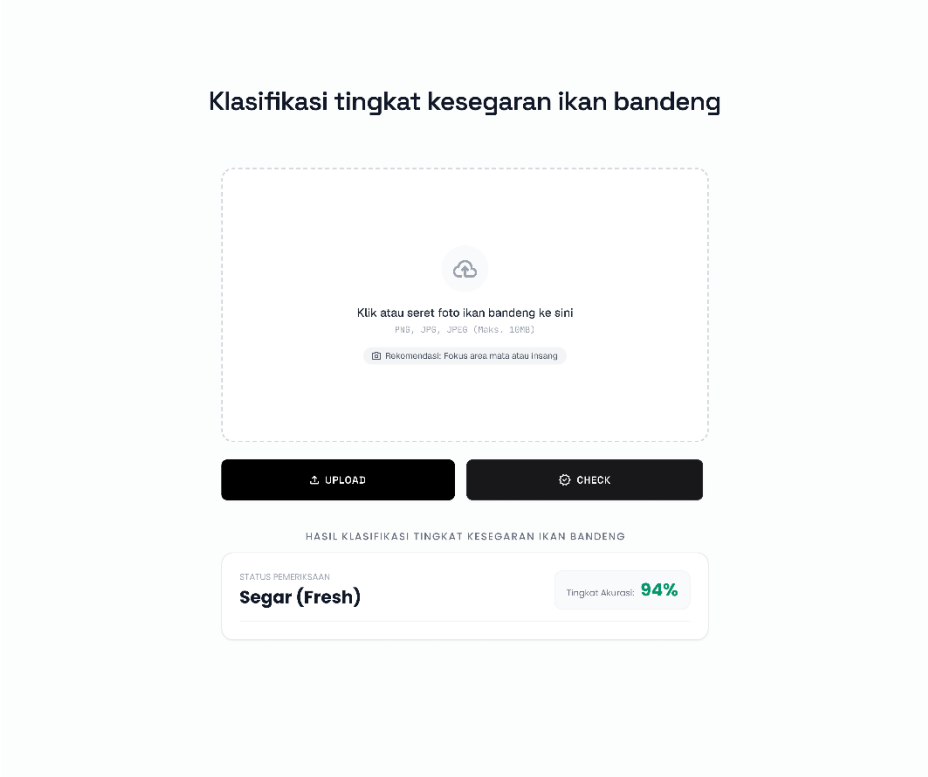
Table 3.5 Skenario Pengujian

No.	Skenario Pengujian	Variasi Fitur
1	Model	Mata
		Insang
		Mata + Insang
2	Variasi Nilai C	10
		1,0
		0,1
3	Nilai Gamma	0,1
		0,01
		0,001
4	Kernel	Linear
		RBF
5	Strategi Multi-Class	One-vs-Rest (OvR)
		One-vs-One (OvO)

Pada setiap skenario model, proses pelatihan dan pemilihan konfigurasi *hyperparameter* dilakukan menggunakan data pengembangan melalui *cross-validation*. Skenario pengujian mencakup perbandingan penggunaan citra mata, citra insang, dan gabungan citra mata dan insang melalui *feature-level fusion*, serta variasi konfigurasi algoritma Support Vector Machine (SVM) yang meliputi jenis kernel, nilai parameter C, nilai gamma pada kernel RBF, dan strategi klasifikasi multikelas. Konfigurasi model terbaik ditentukan berdasarkan hasil evaluasi pada data validasi dalam proses *cross-validation*. Setelah konfigurasi terbaik diperoleh, model dilatih kembali menggunakan seluruh data pengembangan dan selanjutnya diuji pada data uji akhir untuk memperoleh performa akhir model.

3.7. Implementasi *Website*

Setelah proses perancangan dan pelatihan model dilakukan, tahap selanjutnya adalah implementasi *website*. Implementasi *website* menggunakan *framework* Flask yang dimulai dengan membuat rancangan alur dan model tampilan untuk memudahkan proses pengembangan selanjutnya. *Website* ini berfungsi sebagai antarmuka yang memungkinkan pengguna mengunggah pasangan citra mata dan insang ikan bandeng untuk kemudian diklasifikasikan tingkat kesegarannya oleh model yang telah dilatih. Rancangan model tampilan *website* ditampilkan pada Gambar 3.12.



Gambar 3.12 *Wireframe Website*

Wireframe pada Gambar 3.11 berperan sebagai panduan dalam perancangan antarmuka aplikasi berbasis Flask. Langkah selanjutnya melibatkan perancangan arsitektur sistem, yang mencakup organisasi direktori untuk komponen utama aplikasi, template antarmuka, serta model yang telah dilatih. Proses integrasi dilakukan untuk menyelaraskan antarmuka pengguna dengan *backend* yang telah dimodelkan menggunakan kombinasi MobileNetV3-Small dan SVM. Data berupa pasangan citra mata dan insang yang dimasukkan oleh pengguna akan melalui tahap *preprocessing* sebelum dianalisis oleh model, yang kemudian menghasilkan klasifikasi kesegaran ikan ke dalam salah satu dari tiga kelas, yaitu Segar Tidak Segar, dan Busuk. Hasil klasifikasi tersebut kemudian ditampilkan kepada pengguna melalui antarmuka *website*.

DAFTAR PUSTAKA

[1] A. A. Rahma, R. S. Nurlaela, A. Meilani, Z. P. Saryono, and A. D. Pajrin, "Ikan Sebagai Sumber Protein dan Gizi Berkualitas Tinggi Bagi Kesehatan Tubuh Manusia," *Karimah Tauhid*, vol. 3, no. 3, pp. 3132–3142, 2024, doi: 10.30997/karimahtauhid.v3i3.12341.

[2] A. Tamsil, H. Hasnidar, and M. Abyandi, "RESPON PERTUMBUHAN IKAN BANDENG, Chanos chanos Forsskal, 1775 MENGGUNAKAN TEPUNG IKAN SAPU-SAPU Pterygoplichthys pardalis," *J. Perikan. Unram*, vol. 14, pp. 380–389, 2024, doi: 10.29303/jp.v14i1.788.

[3] M. G. Pradiga and S. Saino, "Analisis faktor yang mempengaruhi keputusan pembelian generasi z pada produk olahan bandeng," *J. Manaj.*, vol. 14, no. 2, pp. 221–231, Jun. 2022, doi: 10.30872/jmmn.v14i2.11186.

[4] M. N. Madhubhashini, C. P. Liyanage, A. U. Alahakoon, and R. P. Liyanage, "Current applications and future trends of artificial senses in fish freshness determination: A review," *J. Food Sci.*, vol. 89, no. 1, pp. 33–50, 2024, doi: 10.1111/1750-3841.16865.

[5] İ. Akgül, V. Kaya, and Ö. Z. Tanir, "A novel hybrid system for automatic detection of fish quality from eye and gill color characteristics using transfer learning technique," *PLoS One*, vol. 18, no. 4 April, 2023, doi: 10.1371/journal.pone.0284804.

[6] M. B. Yildiz, E. T. Yasin, and M. Koklu, "Fisheye freshness detection using common deep learning algorithms and machine learning methods with a developed mobile application," *Eur. Food Res. Technol.*, vol. 250, no. 7, pp. 1919–1932, 2024, doi: 10.1007/s00217-024-04493-0.

[7] E. Prasetyo, R. Purbaningtyas, R. D. Adityo, E. T. Prabowo, and A. I. Ferdiansyah, "Perbandingan Convolution Neural Network Untuk Klasifikasi Kesegaran Ikan Bandeng Pada Citra Mata," *J. Teknol. Inf. dan Ilmu Komput.*, vol. 8, no. 3, p. 601, Jun. 2021, doi: 10.25126/jtiik.2021834369.

[8] A. N. Hidayatullah, E. Prasetyo, and R. Purbaningtyas, "Identifikasi Kesegaran Ikan Bandeng Non-kontak menggunakan MobileNetV2," vol. 6, no. 2, pp. 416–426, 2024, doi: 10.36499/jinrpl.v6i2.10860.

[9] D. C. Kurniasari, A. P. Sari, and H. Maulana, "Identifikasi Kualitas Ikan Bandeng Melalui Citra Mata Menggunakan Svm," *JIPI (Jurnal Ilm. Penelit.*

dan Pembelajaran Inform., vol. 11, no. 2, pp. 962–970, 2026, doi: 10.29100/jipi.v11i2.7843.

[10] Y. Darnita, R. Toyib, A. Sonita, and A. Putra, "Automated Classification of Mungkus Fish Freshness Based on Eye and Gill Images Using the Naive Bayes Algorithm," *J. Tek. Inform.*, vol. 6, no. 4, pp. 2107–2122, 2025, doi: 10.52436/1.jutif.2025.6.4.5146.

[11] Y. Darnita, F. A. Putra, S. H. Wibowo, S. A. Saputera, and N. D. Maria Veronika, "Penerapan Metode Convolutional Neural Network Dalam Klasifikasi Kesegaran Ikan Mungkus Berdasarkan Citra Mata dan Insang Ikan," *J. Inform.*, vol. 25, no. 1, pp. 59–73, 2025, doi: 10.30873/jurnalinformatika.v25i4.

[12] Adela Regita Azzahra, Purnawansyah, H. Darwis, and D. Widyawati, "Klasifikasi Daun Herbal Menggunakan Metode CNN dan Naïve Bayes dengan Fitur GLCM," *Indones. J. Comput. Sci.*, vol. 12, no. 4, pp. 284–301, Aug. 2023, doi: 10.33022/ijcs.v12i4.3362.

[13] A. G. da Silva, R. P. de Oliveira, C. de Oliveira Bastos, E. A. de Carvalho, and B. D. Gomes, "A mobile hybrid deep learning approach for classifying 3D-like representations of Amazonian lizards," *Front. Artif. Intell.*, vol. 8, no. August, pp. 1–10, 2025, doi: 10.3389/frai.2025.1524380.

[14] M. Carolina, S. Tendean, and K. Krisyesika, "Penerapan Metode Support Vector Machine Pada Aplikasi Deteksi Tingkat Kesegaran Ikan," *Inteksis*, vol. 11, no. 2, pp. 35–45, 2024, doi: 10.66003/inteksis.v11i2.10427.

[15] S. Saputra *et al.*, "Identifikasi Kesegaran Ikan Menggunakan Algoritma KNN Berbasis Citra Digital," *J. Tek. Inform.*, vol. 10, no. 1, pp. 1–9, 2022, doi: 10.32832/kreatif.v10i1.6845.

[16] E. Ekojono, A. wegi Herman, and M. Mustika, "Identification of Freshness of Marine Fish Based on Image of Hue Saturation Value and Morphology," *Inf. J. Ilm. Bid. Teknol. Inf. dan Komun.*, vol. 6, no. 1, pp. 40–48, 2021, doi: 10.25139/inform.v6i1.3228.

[17] P. Studi, T. Hasil, F. Pertanian, and U. P. Raya, "EFEKTIVITAS PENAMBAHAN DAUN KATUK (Sauropus androgynus) TERHADAP OTAK-OTAK IKAN BANDENG (Chanos chanos) Petrus Senas The Effectiveness of Adding Sweet Leaf (Sauropus androgynus) to Milkfish (

Chanos chanos) Otak-Otak," vol. 26, pp. 164–176, 2023.

[18] R. Faurina, R. Mahendra, E. Faculty, and U. Bengkulu, "FISH FRESHNESS PREDICTION WITH CONVOLUTIONAL NEURAL NETWORK PREDIKSI KESEGARAN IKAN DENGAN METODE CONVOLUTIONAL NEURAL," vol. 5, no. 3, pp. 883–890, 2024.

[19] Z. Arif and M. Lutfi, "Identifikasi Kesegaran Ikan Berdasarkan Citra Insang dengan Metode Deep Convolution Neural Network," vol. 11, no. September, pp. 1–6, 2022.

[20] Y. Yuhandri, A. R., and H. Syahputra, "Pengenalan Teknologi Pengolahan Citra Digital," *Community Dev. J. J. Pengabdi. Masy.*, vol. 3, no. 2, pp. 1239–1244, 2022.

[21] E. F, Streib and M. Dehmer, "WIREs Data Min Knowl - 2022 - Emmert-Streib - Taxonomy of machine learning paradigms A data-centric perspective.pdf," 2022.

[22] S. Cong and Y. Zhou, "A review of convolutional neural network architectures and their optimizations," *Artif. Intell. Rev.*, vol. 56, no. 3, pp. 1905–1969, 2023, doi: 10.1007/s10462-022-10213-5.

[23] X. Zhao, L. Wang, Y. Zhang, X. Han, M. Deveci, and M. Parmar, *A review of convolutional neural networks in computer vision*, vol. 57, no. 4. Springer Netherlands, 2024. doi: 10.1007/s10462-024-10721-6.

[24] G. Doğan and B. Ergen, "A new hybrid mobile CNN approach for crosswalk recognition in autonomous vehicles," *Multimed. Tools Appl.*, vol. 83, no. 26, pp. 67747–67762, 2024, doi: 10.1007/s11042-024-18199-8.

[25] C. Cui *et al.*, "Deep multimodal fusion of image and non-image data in disease diagnosis and prognosis: a review," *Prog. Biomed. Eng.*, vol. 5, no. 2, p. 022001, Apr. 2023, doi: 10.1088/2516-1091/acc2fe.

[26] N. P. Batubara, D. Widiyanto, and N. Chamidah, "Klasifikasi rempah rimpang berdasarkan ciri warna rgb dan tekstur glcm menggunakan algoritma naive bayes," *Inform. J. Ilmu Komput.*, vol. 16, no. 3, p. 156, 2020, doi: 10.52958/iftk.v16i3.2196.

[27] M. F. Naufal and S. F. Kusuma, "Analisis Perbandingan Algoritma Machine Learning dan Deep Learning untuk Klasifikasi Citra Sistem Isyarat Bahasa Indonesia (SIBI)," *J. Teknol. Inf. dan Ilmu Komput.*, vol. 10, no. 4, pp. 873–

882, 2023, doi: 10.25126/jtiik.2024106823.

[28] P. Projects, “Flask Documentation.” Accessed: Sep. 25, 2026. [Online]. Available: https://flask.palletsprojects.com/en/stable/